



Frankfurt University of Applied Sciences

Fachbereich 2: Informatik und Ingenieurwissenschaften

Masterarbeit

Wissenschaftliche Berichtsabgabe zur Masterarbeit

Thema:

„KI-basierte Anomalieerkennung auf ressourcenbeschränkter Edge-Hardware“

Erster Prüfer: Herr Prof. Dr. Karsten Schmidt

Zweite Prüferin: Frau M.Sc. Virginia Kramer

Studiengang: Mechatronik und Robotik

Bearbeiter: Abdulmalik Alzubi

Matrikelnummer: 1224063

Zeitraum: 26.05.2026 – 27.10.2026

Abgabedatum: 27.10.2026

Erklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbständig erstellt und keine anderen als die angegebenen Hilfsmittel benutzt habe.

Soweit ich auf fremde Materialien, Texte oder Gedankengänge zurückgegriffen habe, enthalten meine Ausführungen vollständige und eindeutige Verweise auf die Urheber und Quellen.

Alle weiteren Inhalte der vorgelegten Arbeit stammen von mir im urheberrechtlichen Sinn, soweit keine Verweise und Zitate erfolgen.

Datum: Frankfurt, den _____

Unterschrift: _____

Abdulmalik Alzubi

Inhaltsverzeichnis

Erklärung.....	i
Abbildungsverzeichnis.....	iv
Tabellenverzeichnis.....	v
Abkürzungsverzeichnis.....	vi
1 Einleitung, Problemstellung und Zielsetzung.....	1
1.1 Ausgangssituation und Motivation.....	1
1.2 Wissenschaftliche Problemstellung.....	1
1.3 Zielsetzung der Arbeit.....	1
1.4 Forschungsfragen und Hypothesen.....	2
1.5 Abgrenzung der Arbeit.....	2
1.6 Aufbau der Arbeit.....	3
2 Theoretische Grundlagen.....	4
2.1 Zustandsüberwachung und Anomalieerkennung.....	4
2.2 Verfahrensklassen für die Anomalieentscheidung.....	4
2.2.1 Statistische Schwellenwertverfahren.....	4
2.2.2 Klassische Verfahren im Normaldaten-Szenario.....	4
2.2.3 Autoencoder.....	5
2.3 Messdaten und Fensterbildung.....	5
2.4 Datenaufteilung und Vorverarbeitung.....	5
2.5 Schwellenwertkalibrierung.....	6
2.6 Erkennungsqualität und Aussagekraft der Evaluation.....	6
2.7 Lokale Ausführung und Zeitverhalten.....	7
2.8 Veränderte Normalbedingungen.....	7
3 Stand der Technik und verwandte Arbeiten.....	8
3.1 Datenbasis und Messbedingungen.....	8
3.2 Verfahren und Edge-Ausführung.....	8
3.3 Vergleich ausgewählter Arbeiten.....	9
3.4 Forschungslücke und Einordnung der eigenen Arbeit.....	9
4 Anforderungsanalyse.....	10
4.1 Messdaten und Vergleichsbasis.....	10
4.2 Lokale Verarbeitung und Zeitverhalten.....	10
4.3 Evaluation.....	11
4.4 Kernanforderungen und Nachweis.....	11
5 Variantenvergleich und Systementscheidung.....	14
5.1 Bewertungsrahmen und Vorgehen.....	14
5.2 Bewertung der Prüfstandsalternativen.....	15
5.3 Auswahl von Sensorik und Edge-Plattform.....	17
5.4 Datenbasis, Signalrepräsentation und Verfahren.....	19
5.5 Kriterienbasierte Bewertung der Softwarealternativen.....	21
5.6 Systementscheidung und Übergang zur Implementierung.....	23
6 Implementierung.....	25
6.1 Prüfstand, Aufbauversionen und Zustandsnachweise.....	25
6.2 Hardware-PWM und Ablaufsteuerung.....	26

6.3	Sensorerfassung, Zeitbasis und Qualitätskennzeichnung.....	27
6.4	Gemeinsame Fensterbildung und Vorverarbeitung.....	28
6.5	Modellpaket, Training und Kalibrierung.....	29
6.6	Lokaler Datenweg und Ressourceninstrumentierung.....	31
6.7	Festgelegte Versuche und Nachweisgrenzen.....	32
7	Evaluation und Ergebnisse.....	33
7.1	Datenbasis und Auswertungseinheit.....	33
7.2	Erfassungsqualität und physikalische Zeitbasis.....	34
7.3	Fehlalarme bei unverändertem Normalbetrieb.....	35
7.4	Kontrollierte Luftstromveränderung und Rückkehrreferenz.....	35
7.5	Explorative Fehleranalyse der Modellentscheidungen.....	38
7.6	Zweiter normaler Betriebspunkt bei 50 % PWM.....	40
7.7	Laufzeit, Ressourcen und lokaler Sensorbetrieb.....	41
7.8	Erfüllungsgrad der Anforderungen.....	46
8	Diskussion.....	48
8.1	Aussagekraft des Methodenvergleichs.....	48
8.2	Einlaufzeit, Aufstellung und Vorverarbeitung.....	48
8.3	Technische Grenzen und Übertragbarkeit.....	49
9	Ausblick und verbleibende Nachweise.....	51
10	Fazit.....	53
	Anhang.....	54
	Digitale Belege und Zuordnung.....	54
	Ergänzende Kennzahlen des kontrollierten Zustandslabels.....	55
	Lesen der Messdateien.....	55
	Literaturverzeichnis.....	57

Abbildungsverzeichnis

Abbildung 7-1: Eingefrorene Scores auf identischen 128er-Fenstern der unabhängigen Folge. Die gestrichelten Linien sind die vorab fixierten Schwellen. Diese Verläufe sind von den 5-s-RMS-Werten zu unterscheiden. Quelle: eigene unveränderte Testauswertung.....	36
Abbildung 7-2: Vollständige 5-s-RMS-Verläufe der unabhängigen Folge Normal → Platte → Normal. Die Markierung bei 180 s kennzeichnet den vorab gewählten Prüfabschnitt. Quelle: eigene Messungen vom 12.09.2026.....	37
Abbildung 7-3: Achsenbeiträge zur physischen Energie, zur standardisierten Energie und zum Autoencoder-Fehler auf denselben 128er-Fenstern. Dargestellt sind Mittelwerte je Aufnahme; sie ersetzen nicht die Entscheidungen einzelner Fenster. Quelle: eigene explorative Auswertung.....	39
Abbildung 7-4: Fehlalarmraten je vollständiger Normalaufnahme und zusammengefasst bei 75 % und 50 % PWM mit demselben eingefrorenen Paket. Die Aufnahmen sind nicht zeitgleich oder randomisiert gepaart. Quelle: eigene Testauswertung.....	41
Abbildung 7-5: Verarbeitungslatenz aus drei eigenen Prozessen je Methode und Betriebsart. Punkte zeigen P99, Linien den Bereich vom Median zum Maximum; die gestrichelte Linie kennzeichnet das kleinste beobachtete Fensterintervall. Quelle: eigene Laufzeitmessungen.....	43
Abbildung 7-6: CPU- und RSS-Verläufe im Sensor-Livebetrieb. Zur Darstellung wurden die CPU-Werte in 1-s-Abschnitten zeitgewichtet und die RSS-Werte gemittelt; die Kennwerte der Tabelle verwenden die ursprünglichen zeitgewichteten Messintervalle. Quelle: eigene Laufzeitmessungen.....	44

Tabellenverzeichnis

Tabelle 2-1: Kennzahlen der binären Anomalieerkennung.....	6
Tabelle 3-1: Ausgewählte Vorarbeiten und ihre Bedeutung für die Untersuchung.....	9
Tabelle 4-1: Anforderungen, Prioritäten und Nachweise.....	12
Tabelle 5-1: Bewertung der Prüfstandsalternativen.....	15
Tabelle 5-2: Kriterien und Gewichte für den Prüfstand.....	16
Tabelle 5-3: Gewichtete Bewertung der Prüfstandsalternativen.....	16
Tabelle 5-4: Vergleich der Sensorik und Messketten.....	17
Tabelle 5-5: Bewertung der Edge-Plattformen.....	18
Tabelle 5-6: Kriterien und Gewichte für die Edge-Plattform.....	18
Tabelle 5-7: Gewichtete Bewertung der Edge-Plattformen.....	18
Tabelle 5-8: Bewertung der Signalrepräsentationen.....	19
Tabelle 5-9: Auswahl der Anomalieverfahren.....	20
Tabelle 5-10: Kriterienbasierter Vergleich der Softwarealternativen.....	21
Tabelle 5-11: Kriterien und Gewichte für die Softwareauswahl.....	22
Tabelle 5-12: Gewichtete Bewertung der Softwarealternativen.....	22
Tabelle 5-13: Systementscheidungen und ausstehende Nachweise.....	23
Tabelle 6-1: Prüfstand und Bedeutung der dokumentierten Größen.....	25
Tabelle 6-2: Unveränderte Sensorkonfiguration der v4-Messkette.....	27
Tabelle 6-3: Architektur des ausgeführten Autoencoders.....	29
Tabelle 6-4: Scores und eingefrorene Entscheidungsschwellen.....	30
Tabelle 6-5: Komponenten des geprüften Datenwegs.....	31
Tabelle 7-1: Aufnahmen für Entwicklung und unabhängige Erkennungsprüfung.....	33
Tabelle 7-2: Unabhängige Normalaufnahmen bei 75 % PWM.....	35
Tabelle 7-3: Entscheidungen der drei Methoden in der vollständigen Plattenfolge.....	35
Tabelle 7-4: Physikalischer Vektor-AC-RMS der 5-s-Abschnitte von 180 bis 300 s.....	36
Tabelle 7-5: Mittlerer Autoencoder-Rekonstruktionsfehler je Achse auf identischen Modellfenstern.....	38
Tabelle 7-6: Fehlalarme im zweiten normalen Betriebspunkt.....	40
Tabelle 7-7: Latenz je Methode und Betriebsart; Bereich der drei getrennten Prozesse.....	42
Tabelle 7-8: Prozessressourcen im aktiven Abschnitt [180,300) s; Bereich der drei Prozesse.....	43
Tabelle 7-9: Nachweisstand der Anforderungen A1–A13.....	46
Tabelle A-1: Verzeichnis der maßgeblichen digitalen Belege.....	54
Tabelle A-2: Verwechslungszahlen der einen Plattenfolge auf identischen Fenstern.....	55
Tabelle A-3: Deskriptive Kennzahlen für das Zustandslabel; alle Angaben in Prozent.....	55

Abkürzungsverzeichnis

Abkürzung	Bedeutung
AE	Autoencoder
CPU	Central Processing Unit
DFT	Diskrete Fourier-Transformation
FFT	Fast Fourier Transform
FPR	False-Positive-Rate
GPIO	General Purpose Input/Output
GUI	Graphical User Interface (grafische Benutzeroberfläche)
I ² C	Inter-Integrated Circuit
IEPE	Integrated Electronics Piezo-Electric
KI	Künstliche Intelligenz
MCU	Microcontroller Unit
ML	Machine Learning
MSE	Mean Squared Error
ODR	Output Data Rate
PWM	Pulsweitenmodulation
RAM	Random Access Memory
RMS	Root Mean Square
RSS	Resident Set Size
SBC	Single-Board Computer
SPI	Serial Peripheral Interface
TFLite	TensorFlow Lite
AC	Wechselanteil nach Entfernung des Gleichanteils
IF	Isolation Forest
LSB	Least Significant Bit
MiB	Mebibyte (2 ²⁰ Byte)
P99	Empirisches 99. Perzentil
PSD	Power Spectral Density (Leistungsdichtespektrum)

1 Einleitung, Problemstellung und Zielsetzung

1.1 Ausgangssituation und Motivation

Beschleunigungssignale ermöglichen es, Schwingungen technischer Systeme zu beobachten. Bei rotierenden Komponenten können Veränderungen dieser Signale auf einen veränderten Zustand hinweisen. Randall und Antoni (2011) erläutern dies am Beispiel der Wälzlagerdiagnose. Die vorliegende Arbeit untersucht die lokale Erkennung solcher Abweichungen anhand von Beschleunigungsdaten.

Die Auswertung soll lokal in der Nähe des Sensors erfolgen. Dieses Prinzip des Edge Computing kann die Übertragung von Rohdaten und die Abhängigkeit von entfernten Rechendiensten verringern (Shi et al., 2016). Neben einer guten Erkennung sind deshalb der Rechen- und Speicherbedarf sowie die Verarbeitungszeit wichtig. Zusätzlich wird untersucht, wie sich veränderte normale Messbedingungen auf die Entscheidungen auswirken.

1.2 Wissenschaftliche Problemstellung

Bei der normalitätsbasierten Anomalieerkennung wird ein Referenzmodell aus normalen Messdaten gebildet. Neue Daten gelten als auffällig, wenn sie ausreichend von dieser Referenz abweichen. Dieses Vorgehen benötigt keine vollständige Sammlung möglicher Fehlerbeispiele. Seine Aussagekraft hängt jedoch davon ab, welche Normalbedingungen die Referenzdaten abdecken (Chandola et al., 2009).

Für einen belastbaren Vergleich müssen die Verfahren unter vergleichbaren Bedingungen bewertet werden. Informationen aus dem Test dürfen weder die Modellwahl noch die Vorverarbeitung oder die Entscheidungsschwelle beeinflussen; andernfalls kann die Erkennungsleistung überschätzt werden (Kaufman et al., 2012). Außerdem muss die gesamte Verarbeitung auf der Zielhardware betrachtet werden. Eine kurze Modellinferenz allein zeigt noch nicht, ob alle eingehenden Daten rechtzeitig verarbeitet werden.

1.3 Zielsetzung der Arbeit

Ziel ist die Konzeption, Umsetzung und experimentelle Bewertung einer lokalen Verarbeitungskette (Pipeline) für mehrkanalige Beschleunigungsdaten. Verglichen werden ein neuronales Hauptverfahren, eine statistische Schwellenwertbaseline und ein klassisches Lernverfahren. Auch das klassische Verfahren gehört zum maschinellen Lernen. Die konkrete Auswahl des Systems und des Versuchsaufbaus wird in Kapitel 5 anhand der Anforderungen und eines Variantenvergleichs begründet.

Der Beitrag ist der gemeinsame Vergleich von Erkennungsqualität und technischem Aufwand. Ein Zusatzversuch untersucht die Grenzen der unveränderten Pipeline bei geänderten Normalbedingungen.

1.4 Forschungsfragen und Hypothesen

Zentrale Forschungsfrage: Wie lässt sich eine lokale Anomalieerkennung für mehrkanalige Beschleunigungsdaten auf ressourcenbeschränkter Edge-Hardware umsetzen und hinsichtlich Erkennungsqualität, Ressourcenbedarf, Zeitverhalten und veränderter Normalbedingungen bewerten?

FF1: Welche Anforderungen ergeben sich aus der Aufgabe, und wie begründen sie die Auswahl von Versuchsaufbau, Sensorik, Hardware und Verfahren?

FF2: Wie unterscheiden sich Hauptverfahren und Baselines bei gleichen Testfenstern und einer einheitlichen Schwellenwertkalibrierung auf Normaldaten hinsichtlich Precision, Recall, F1-Score und Fehlalarmrate?

FF3: Wie viel Speicher und Rechenleistung benötigt die lokale Pipeline, und wie häufig überschreitet ihre Verarbeitung das Zeitbudget bis zum nächsten Fenster?

FF4: Wie verändert sich die Fehlalarmrate bei gezielt geänderten Normalbedingungen, wenn Vorverarbeitung, Modell und Schwelle unverändert bleiben?

Die Arbeitshypothesen legen die Vergleichsgrößen fest. Bereits zur Entwicklung verwendete Daten werden explorativ ausgewertet. Eine unabhängige Bestätigung erfordert neue Testaufnahmen und ein vor deren Auswertung festgelegtes Versuchsprotokoll.

H1 – Erkennungsqualität: Das neuronale Hauptverfahren erreicht bei den definierten Versuchsanomalien einen höheren F1-Score als die statistische Baseline. Diese Erwartung beruht auf der möglichen Nutzung von Informationen, die ein einzelner Kennwert nicht abbildet. Bewertet werden die F1-Differenz auf derselben Testmenge sowie Fehlalarme und übersehene Anomalien.

H2 – Zeitverhalten: Das empirische 99. Perzentil (P99) der Verarbeitungslatenz liegt unter dem Fensterintervall S/f_s . Die Latenz reicht vom vollständigen Fenster bis zur verfügbaren Entscheidung. S bezeichnet die Schrittweite in Messzeitpunkten, f_s die aus Zeitstempeln ermittelte Erfassungsrate. Fristüberschreitungen werden zusätzlich gezählt; P99 garantiert keine fristgerechte Ausgabe jeder Entscheidung.

H3 – Veränderte Normalbedingungen: Bei unveränderter Pipeline steigt die Fehlalarmrate unter der untersuchten veränderten Normalbedingung. Verglichen werden die Fehlalarmraten vor und nach der Änderung. Eine Ursache lässt sich nur bei kontrollierten weiteren Einflüssen zuordnen.

1.5 Abgrenzung der Arbeit

Die Ergebnisse gelten für die untersuchten Bedingungen und die im Versuchsprotokoll definierten Anomalien. Deren Erkennung erlaubt weder eine gesicherte Schadensdiagnose noch eine Prognose der Restlebensdauer. Die Übertragung auf andere Systeme und den industriellen Dauerbetrieb erfordert weitere Untersuchungen.

Der Kernversuch bewertet die lokale Inferenz eines zuvor trainierten Modells auf einer Zielplattform. Die Pipeline bleibt dabei unverändert. Eine ergänzende Nachkalibrierung wird gesondert ausgewertet.

1.6 Aufbau der Arbeit

Kapitel 2 und 3 erläutern Grundlagen und Vorarbeiten. Darauf folgen Anforderungen (Kapitel 4), Variantenvergleich und Versuchsaufbau (Kapitel 5), Implementierung (Kapitel 6) und Evaluation (Kapitel 7). Diskussion und Ausblick ordnen Grenzen und weitere Untersuchungen ein; das Fazit beantwortet die Forschungsfragen.

2 Theoretische Grundlagen

Dieses Kapitel erklärt die benötigten Begriffe, mögliche Verfahren und die Messgrößen für die Evaluation. Die dargestellten Ansätze bilden die Grundlage für den Variantenvergleich; ihre Auswahl für das System erfolgt erst in Kapitel 5.

2.1 Zustandsüberwachung und Anomalieerkennung

Zustandsüberwachung (Condition Monitoring) erfasst und bewertet den technischen Zustand. Diagnose ordnet Fehlerursachen zu, Prognose schätzt die künftige Zustandsentwicklung (Jardine et al., 2006). Anomalieerkennung bewertet zunächst nur Abweichungen von einer Normalreferenz.

Was als anomal gilt, hängt von Referenz und Betriebskontext ab. Auch ein zeitlicher Verlauf kann auffällig sein, obwohl seine Einzelwerte unauffällig sind (Chandola et al., 2009). Deshalb werden hier Messfenster bewertet.

Klassische und neuronale Verfahren können auf als normal ausgewählten Daten angepasst werden. Dieses Normaldaten-Szenario beschreibt die Trainingsgrundlage und ist von der Algorithmusklasse zu unterscheiden. Der Anomalie-Score ist eine Bewertungsgröße, zunächst keine Schadenswahrscheinlichkeit (Ruff et al., 2021).

2.2 Verfahrensklassen für die Anomalieentscheidung

2.2.1 Statistische Schwellenwertverfahren

Der Effektivwert (Root Mean Square, RMS) eines Kanals mit N Messwerten ist die Quadratwurzel des Mittelwerts der quadrierten Werte:

$$RMS(x) = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2} \quad (2-1)$$

Der RMS fasst die Amplitude eines Fensters zusammen, erhält aber die Reihenfolge der Werte nicht. Für den Fenstermittelwert $\bar{x}$ gilt $RMS^2(x) = \bar{x}^2 + RMS^2(x - \bar{x})$. Ohne Mittelwertentfernung beeinflussen daher auch konstante Anteile den Kennwert. Beschleunigungssensoren erfassen neben Bewegung unter anderem die Gravitation und einen Sensoroffset (Analog Devices, 2022). Rohwert-RMS und RMS nach Mittelwertentfernung sind deshalb zu unterscheiden. Ebenso muss feststehen, wie mehrere Messkanäle zusammengefasst werden.

2.2.2 Klassische Verfahren im Normaldaten-Szenario

Isolation Forest nutzt zufällige Teilungsbäume. Jeder Schritt teilt die Daten anhand eines zufällig gewählten Merkmals und Teilungspunkts. Beobachtungen, die im Mittel durch wenige Teilungen isoliert werden, gelten als auffälliger (Liu et al., 2008). Im Normaldaten-Szenario erfolgt seine Anpassung ausschließlich anhand normaler Beobachtungen.

Die Eingabe ist ein Vektor fester Länge aus Fensterkennwerten oder aneinandergereihten Messwerten. Die verwendete Darstellung und die Richtung des ausgegebenen Scores müssen dokumentiert werden.

2.2.3 Autoencoder

Ein Autoencoder erzeugt aus einer Eingabe x eine Rekonstruktion $\hat{x}$. Der Encoder bildet die Eingabe auf eine interne Darstellung ab, der Decoder rekonstruiert daraus die Ausgangswerte. Eine begrenzte Modellkapazität oder Regularisierung soll bloßes Kopieren verhindern (Goodfellow et al., 2016). Als Anomalie-Score kann der mittlere quadratische Rekonstruktionsfehler verwendet werden:

$$s(x) = MSE(x, \hat{x}) = \frac{1}{d} \sum_{j=1}^d (x_j - \hat{x}_j)^2 \quad (2-2)$$

Dabei bezeichnet d die Zahl der verglichenen Einzelwerte. Für ein Fenster mit H Messzeitpunkten und C Kanälen gilt $d = HC$. Der Score hängt von der Skalierung und der Mittelung ab. Bei standardisierten Eingaben ist er dimensionslos.

Die Annahme lautet, dass ein auf Normaldaten trainierter Autoencoder auffällige Eingaben schlechter rekonstruiert. Das ist keine allgemeine Garantie: Auch bestimmte Anomalien können gut rekonstruiert werden (Ruff et al., 2021). Ob der Score die definierten Versuchsanomalien trennt, muss daher experimentell geprüft werden.

2.3 Messdaten und Fensterbildung

Bei dreiachsigen Messungen enthält jeder Messvektor beispielsweise einen X-, Y- und Z-Wert. Sensorausgaberate, Signalbandbreite und Abfragerate der Software sind unterschiedliche Größen. Häufigeres Auslesen erzeugt nicht automatisch neue Sensorwerte. Die Abstimmung von Sensorkonfiguration und Datenabruf ist daher zu prüfen (Analog Devices, 2022).

Ein Fenster bündelt H aufeinanderfolgende Messvektoren. Bei C Messkanälen enthält es HC Werte. Die Schrittweite S bestimmt, nach wie vielen neuen Messzeitpunkten das nächste Fenster beginnt. Bei gleichmäßiger Erfassung beträgt das Fensterintervall S/f_s . Für die Zeitbewertung wird f_s aus den Zeitstempeln bestimmt; ob jeder erfasste Vektor eine neue Sensormessung enthält, wird getrennt geprüft.

Bei ungleichmäßiger Erfassung und Datenlücken reichen nominelle Zeitangaben nicht aus. Die tatsächlich erfassten Zeitstempel müssen deshalb erhalten bleiben.

2.4 Datenaufteilung und Vorverarbeitung

Trainingsdaten dienen zur Anpassung des Modells. Validierungsdaten unterstützen die Auswahl von Einstellungen und die Kalibrierung. Die Testdaten bleiben bis zur abschließenden Bewertung ungenutzt. Vollständige Aufnahmen bilden dabei Gruppen und

werden vor der Fensterbildung getrennt zugeordnet. So werden ähnliche Abschnitte derselben Aufnahme nicht auf Training und Test verteilt (scikit-learn developers, o. J. b).

Data Leakage liegt vor, wenn Informationen in die Entwicklung einfließen, die bei der vorgesehenen Anwendung nicht verfügbar wären. Ein Beispiel ist die Standardisierung mit Mittelwert und Standardabweichung der gesamten Datenmenge. Solche Parameter dürfen nur aus Trainingsdaten bestimmt werden. Danach werden sie unverändert auf Validierungs-, Test- und Live-Daten angewendet (scikit-learn developers, o. J. a).

Fenster derselben Aufnahme sind keine unabhängigen Messläufe. Auch getrennte Aufnahmen können bei gleicher Montage sehr ähnlich sein. Die Aussagekraft hängt daher von Zahl und Vielfalt der Messläufe ab.

2.5 Schwellenwertkalibrierung

Aus dem Anomalie-Score wird durch einen Schwellenwert eine Entscheidung. Für den Vergleich werden die Scores so ausgerichtet, dass größere Werte eine stärkere Auffälligkeit bedeuten. Die Entscheidung lautet dann anomal, wenn der Score die festgelegte Schwelle überschreitet.

Eine mögliche Kalibrierung nutzt ein hohes empirisches Quantil der Scores separater Normaldaten. Ein Quantil bezeichnet einen Grenzwert in der sortierten Verteilung. Die konkrete Quantilsregel wird für alle Verfahren vor der Testauswertung festgelegt. Damit wird dieselbe Kalibrierungsregel verwendet, auch wenn die numerischen Schwellen verschieden sind.

Eine so bestimmte Schwelle garantiert keine bestimmte Fehlalarmrate auf späteren Aufnahmen. Dafür müssen die neuen Normaldaten ausreichend zur Kalibrierungsgrundlage passen. Eine nachträgliche Anpassung anhand der Testgüte würde die unabhängige Bewertung aufheben (scikit-learn developers, o. J. a).

2.6 Erkennungsqualität und Aussagekraft der Evaluation

Die positive Klasse ist die definierte Anomalie. Die Konfusionsmatrix zählt richtig erkannte Anomalien (TP), Fehlalarme (FP), übersehene Anomalien (FN) und richtig erkannte Normalfenster (TN). Daraus ergeben sich die Kennzahlen in Tabelle 2-1 (scikit-learn developers, o. J. c).

Tabelle 2-1: Kennzahlen der binären Anomalieerkennung

Kennzahl	Berechnung	Bedeutung
Precision	$TP / (TP + FP)$	Anteil richtiger Anomalien unter allen Alarmen
Recall	$TP / (TP + FN)$	Anteil erkannter Anomalien unter allen tatsächlichen Anomalien
F1-Score	$2TP / (2TP + FP + FN)$	Harmonisches Mittel von Precision und Recall

Kennzahl	Berechnung	Bedeutung
Fehlalarmrate (FPR)	$FP / (FP + TN)$	Anteil falsch gemeldeter Fenster unter allen Normalfenstern
Accuracy	$(TP + TN) / (TP + TN + FP + FN)$	Anteil aller richtigen Entscheidungen

Eine hohe Accuracy kann bei ungleichen Klassenanteilen täuschen. Deshalb werden die Konfusionsmatrix und mehrere Kennzahlen gemeinsam berichtet. Nicht definierte Werte, etwa Recall ohne Anomalien im Datensatz, werden gekennzeichnet. Für reine Normalaufnahmen steht die Fehlalarmrate im Mittelpunkt. Zusätzlich werden Klassenanteile und Ergebnisse je Aufnahme angegeben.

2.7 Lokale Ausführung und Zeitverhalten

Bei lokaler Ausführung wird das trainierte Modell nahe der Datenquelle ausgewertet (Shi et al., 2016). Ob Rechenleistung und Arbeitsspeicher der Zielplattform ausreichen, muss für die konkrete Anwendung gemessen werden.

Die Modellgröße bezeichnet die gespeicherte Datei. Der Prozessspeicher umfasst zusätzlich unter anderem Bibliotheken, Eingabedaten und Zwischenergebnisse. Modellgröße und Speicherbedarf während der Ausführung sind daher getrennt auszuweisen. Auch die CPU-Auslastung benötigt eine dokumentierte Messdauer und Bezugsgröße.

Die Inferenzzeit umfasst nur die Modellauswertung. Die Verarbeitungslatenz reicht in dieser Arbeit vom vollständigen Fenster bis zur verfügbaren Entscheidung und enthält auch Vorverarbeitung und Wartezeiten. Die Zeit zum Sammeln des Fensters ist darin nicht enthalten. Ein Echtzeitsystem muss seine Ergebnisse innerhalb festgelegter Fristen liefern (Buttazzo, 2011). Mittelwerte allein belegen das nicht.

P95 und P99 beschreiben hohe empirische Perzentile der gemessenen Latenzen. Sie werden zusammen mit Fristüberschreitungen und Erfassungspausen ausgewertet. Trainierte Modelle können für die lokale Ausführung in ein anderes Format konvertiert werden (Google, 2026a). Danach müssen Scores und Entscheidungen erneut geprüft werden.

2.8 Veränderte Normalbedingungen

Ändern sich Montage, Sensororientierung oder Betriebspunkt, können sich normale Eingabedaten von der bisherigen Referenz unterscheiden. Solche Verteilungsänderungen werden häufig als Domain Shift bezeichnet. Sie können die Anomalieerkennung beeinträchtigen (Ruff et al., 2021).

FF4 untersucht deshalb die Fehlalarmrate bei unveränderter Pipeline unter geänderten Normalbedingungen. Eine anschließende Nachkalibrierung ist als eigener Versuch auszuwerten.

3 Stand der Technik und verwandte Arbeiten

Dieses Kapitel vergleicht ausgewählte Originalstudien nach Datenbasis, Lernaufgabe, lokaler Ausführung und Übertragbarkeit. Die gezielte Auswahl mit Recherchestand September 2026 umfasst Arbeiten zu den Forschungsfragen; sie ist keine vollständige systematische Literaturübersicht.

3.1 Datenbasis und Messbedingungen

Lessmeier et al. (2016) untersuchen die überwachte Unterscheidung gesunder Lager sowie von Innen- und Außenringschäden. Sie vergleichen künstlich erzeugte Schäden mit Schäden aus beschleunigten Lebensdauerversuchen. Die Klassifikationsgüte hängt dabei von Schadensherkunft und Verfahren ab. Der Befund betrifft überwachte Lagerklassifikation und lässt sich nicht unmittelbar auf normaldatenbasiertes Training übertragen.

Pittino et al. (2020) untersuchen eine Waferbearbeitungsmaschine bei unterschiedlichen Drehzahlen und Verschleißzuständen. Normaldaten stammen aus funktionsfähigen Kammern, Fehlerdaten aus einem Demonstrator ohne Schmierung. Verglichen werden regressionsbasierte Regelkarten und eine überwachte Support-Vector-Machine-Klassifikation. Letztere nutzt zusätzlich Fehlerbeispiele. Ihr Ergebnis belegt deshalb keinen allgemeinen Vorteil im Normaldaten-Szenario.

Knap et al. (2026) vergleichen klassische und tiefe Klassifikationsverfahren in sechs Übertragungsszenarien auf CWRU- und Paderborner Lagerdaten. Ihr beschriebenes Protokoll trennt vollständige Aufnahmen vor der Fensterbildung. Für die eigene Untersuchung folgt daraus die Trennung ganzer Messläufe. Geänderte Normalbedingungen werden zusätzlich in einem eigenen Versuch betrachtet.

3.2 Verfahren und Edge-Ausführung

Ren et al. (2021) führen mit TinyOL einen Autoencoder auf einem Cortex-M4-Mikrocontroller aus und ermöglichen das lokale Nachlernen seiner letzten Schicht. Dreiachsige Lüftermessungen werden vor der Modelleingabe durch Hauptkomponentenanalyse auf eine Dimension reduziert. Nach erneuter Anbringung des Sensors verändert sich der Rekonstruktionsfehler; die feste Schwelle verursacht mehr Fehlalarme. Die untersuchte Modellanpassung ist von der Bewertung einer unveränderten Pipeline zu unterscheiden.

Antonini et al. (2023) entwickeln einen ESP32-Sensorknoten für die Pumpenüberwachung. Merkmalsbildung, Isolation-Forest-Training und Inferenz laufen lokal; das Training setzt normalen Betrieb voraus. Die Ressourcenmessungen erfolgen am Prüfstand und unterscheiden Laden, Training und Inferenz. Eine Bewertung der Erkennungsgenauigkeit ist ausdrücklich nicht Gegenstand der Studie.

Garay et al. (2026) vergleichen vier Algorithmen in fünf Varianten, darunter Isolation Forest und einen Autoencoder, auf einem Cortex-M4F. Nach einer Sensorneumontage treten mehr

Fehlalarme auf; gleichzeitig verändert sich die Umgebungstemperatur. Ein isolierter Montageeffekt ist daraus nicht ableitbar. Die Autoren untersuchen außerdem eine Nachkalibrierung von Skalierung und Schwelle. Beim Isolation Forest stammen die Erkennungskennzahlen vom Modell mit 100 Bäumen, die Mikrocontrollerwerte von einer Variante mit sechs Bäumen. Beide Größen beschreiben somit unterschiedliche Modellstände.

3.3 Vergleich ausgewählter Arbeiten

Tabelle 3-1 fasst die drei Studien mit eigener Hardwareausführung zusammen. Wegen unterschiedlicher Daten und Messgrenzen erlauben ihre Kennzahlen keine unmittelbare Rangfolge.

Tabelle 3-1: Ausgewählte Vorarbeiten und ihre Bedeutung für die Untersuchung

Arbeit	Daten und Lernaufgabe	Ausführung / Messung	Einordnung für diese Arbeit
Ren et al. (2021)	Lüfter; Autoencoder und Nachlernen	Cortex-M4; Inferenz und Online-Anpassung	Belegt Montageempfindlichkeit; Anpassung getrennt von fester Normalreferenz bewerten
Antonini et al. (2023)	Lüfterprüfstand; Isolation Forest mit Normaltraining	ESP32; Laden, Training und Inferenz	Ressourcen getrennt erfassen; keine Erkennungsbewertung in der Studie
Garay et al. (2026)	Unwuchtversuch; fünf normaltrainierte Modellvarianten	Cortex-M4F; Montage- und Temperaturänderung	Modellstände abgleichen; Nachkalibrierung getrennt bewerten

3.4 Forschungslücke und Einordnung der eigenen Arbeit

Die Vorarbeiten zeigen, dass lokale Anomalieerkennung und die Anpassung an veränderte Messbedingungen bereits untersucht werden. Für die eigene Untersuchung bleibt zu klären, welchen zusätzlichen Erkennungsnutzen ein neuronales Verfahren gegenüber den beiden Baselines bietet und welchen technischen Aufwand es verursacht. Die Arbeit liefert hierzu eine anwendungsbezogene Vergleichsevaluation.

Dafür werden drei Aspekte verbunden: gleiche Testfenster und eine gemeinsame Kalibrierungsregel für FF2, Messungen am tatsächlich ausgeführten Modell für FF3 sowie ein kontrollierter Vergleich unveränderter Pipelines bei geänderten Normalbedingungen für FF4. Damit werden die in den Vorarbeiten erkennbaren Grenzen von Vergleichbarkeit und Übertragbarkeit gezielt berücksichtigt.

Kapitel 4 übersetzt diesen Untersuchungsbedarf in überprüfbare Anforderungen und beantwortet damit den ersten Teil von FF1. Kapitel 5 vergleicht anschließend geeignete Lösungsvarianten und begründet die Auswahl des Systems und des Versuchsaufbaus.

4 Anforderungsanalyse

Dieses Kapitel leitet aus den Forschungsfragen, den Grundlagen und den Grenzen der Vorarbeiten überprüfbare Anforderungen ab. Sie beschreiben die benötigten Funktionen und Bewertungskriterien unabhängig von einer konkreten technischen Lösung.

4.1 Messdaten und Vergleichsbasis

Für die Untersuchung muss ein reproduzierbarer Testaufbau realisiert werden (A11). Er muss Messungen im Normalzustand und unter gezielt hergestellten Anomaliebedingungen ermöglichen. Eine Normalbedingung muss für FF4 unabhängig von der Anomaliedefinition veränderbar sein (A10). Ein sicherer Betrieb ist Voraussetzung für die Messläufe. Versuchsbedingungen, Rücksetzbarkeit und Ablauf sind so zu dokumentieren, dass Messläufe wiederholt werden können.

Die Messdaten müssen die benötigten Beschleunigungskanäle mit Einheit, Zeitstempeln und Aufnahmekennung enthalten (A1). Messbereich, nutzbare Bandbreite, Signal-Rausch-Abstand und zeitliche Erfassung sind für die Versuchszustände zu prüfen. Akzeptanzgrenzen werden vor der abschließenden Testserie festgelegt. Datenlücken, ungültige Werte und Sättigung sind zu kennzeichnen. Für Normal- und Anomaliedaten muss feststehen, ob die Kennzeichnung ganze Aufnahmen oder einzelne Zeitabschnitte beschreibt.

Vollständige Aufnahmen werden vor der Fensterbildung getrennt Training, Validierung oder Test zugeordnet. Fenster dürfen keine Aufnahmegrenzen überschreiten. Training und Schwellenwertkalibrierung verwenden nur Normaldaten. Die Vorverarbeitung wird nach den Regeln aus Abschnitt 2.4 angepasst und unverändert auf spätere Daten angewendet.

Das neuronale Hauptverfahren und die beiden Baselines müssen dieselben Testfenster und Labels verwenden. Fensterlänge und Schrittweite werden gemeinsam festgelegt. Unterschiedliche Eingabedarstellungen und der Umgang mit unvollständigen Fenstern sind zu dokumentieren. Die Schwellen folgen derselben Kalibrierungsregel auf separaten Normaldaten. Modellwahl und Kalibrierung müssen vor der Testauswertung abgeschlossen sein.

4.2 Lokale Verarbeitung und Zeitverhalten

Datenerfassung, Vorverarbeitung und Entscheidung müssen nach dem Start automatisch und ohne Cloud-Dienst auf der Zielhardware laufen (A4). Die Softwareumgebung muss die benötigten Modelloperationen und Schnittstellen unterstützen; Abhängigkeiten und Versionen sind zu dokumentieren (A5, A6). Für jedes gültige Fenster sind Score, Schwelle und die Entscheidung normal/anomal zu speichern. Ungültige Fenster dürfen nicht als normal bewertet werden. Der Betrieb muss ohne Speicherabbruch und ohne stetig wachsenden Verarbeitungsrückstand möglich sein (A8).

Messläufe müssen gezielt gestartet und geordnet beendet werden können (A13). Jeder Lauf erhält eine eindeutige Kennung. Beim Beenden müssen die bis dahin vollständig erfassten

Daten und Ergebnisse gespeichert bleiben. Messdaten, Entscheidungen und die zugehörigen Angaben müssen maschinenlesbar vorliegen und eindeutig zusammengehören (A5).

Als optionale Erweiterung kann eine grafische Benutzeroberfläche zur Live-Anzeige (Live-GUI) entwickelt werden (A12). Sie zeigt den aktuellen Erfassungsstatus sowie Score, Schwelle, Entscheidung und Zeitstempel des zuletzt ausgewerteten Fensters. Fehlende oder veraltete Daten müssen erkennbar sein. Die Anzeige verwendet die Ergebnisse der Verarbeitung und verändert weder Modell noch Schwelle. Der Messbetrieb und die Evaluation müssen auch ohne diese Oberfläche möglich sein.

Für FF3 werden Inferenzzeit und Verarbeitungslatenz nach Abschnitt 2.7 getrennt gemessen. Das Ziel aus H2 ist $P99 \text{ der Verarbeitungslatenz} < S/f_s$. Zusätzlich sind Anzahl und Anteil der Fristüberschreitungen sowie Erfassungspausen zwischen Fenstern zu berichten.

4.3 Evaluation

Für FF2 werden die Kennzahlen aus Abschnitt 2.6 auf derselben Testmenge ermittelt. Anzahl der Aufnahmen, Klassenverteilung und Ergebnisse je Aufnahme sind anzugeben (A9). Für FF3 werden Modellgröße, CPU-Auslastung und Prozessspeicher einschließlich Bibliotheken und Vorverarbeitung auf derselben Zielhardware gemessen (A8). Messbedingungen sowie Software-, Code- und Modellstand müssen nachvollziehbar sein (A5). Bei einer Modellkonvertierung sind numerische Abweichungen und Entscheidungen gegenüber dem Ausgangsmodell zu prüfen; die Prüfdaten und Akzeptanzgrenzen werden vor der Testauswertung festgelegt (A6). Wird die Live-GUI umgesetzt, ist ihr zusätzlicher Einfluss auf Latenz und Ressourcenbedarf bei ansonsten gleichen Bedingungen mit und ohne Anzeige zu messen.

Für FF4 wird eine dokumentierte Normalbedingung gezielt verändert. Vorverarbeitung, Modell und Schwelle bleiben dabei unverändert. Verglichen werden die Fehlalarmraten unter der ursprünglichen und der veränderten Bedingung. Eine Nachkalibrierung ist getrennt auszuwerten.

4.4 Kernanforderungen und Nachweis

Tabelle 4-1 enthält die Anforderungen A1–A13 mit Art, Priorität und Nachweis. F kennzeichnet funktionale Anforderungen an Systemfunktionen. NF bezeichnet nichtfunktionale Anforderungen an Nachvollziehbarkeit, Zeitverhalten und Betriebsstabilität. Methodische Anforderungen (M) betreffen Versuchsplanung und wissenschaftliche Auswertung. MUSS ist verbindlich; KANN bezeichnet die optionale Live-GUI. Ihr Nachweis ist nur bei Umsetzung erforderlich. Kapitel 6 dokumentiert Umsetzung und Prüfprotokoll. Kapitel 7 bewertet die Erfüllung und prüft die Hypothesen. Nichterfüllte technische Ziele und nicht bestätigte Hypothesen werden als Ergebnisse offengelegt.

Tabelle 4-1: Anforderungen, Prioritäten und Nachweise

ID	Art / Priorität	Anforderung	Nachweis
A1	F MUSS	Messdaten mit überprüfter Qualität erfassen	Kanäle, Einheiten und Zeitstempel prüfen; Bandbreite, Signal-Rausch- Abstand, Sättigung und Datenlücken anhand vorab festgelegter Grenzen bewerten
A2	M MUSS	Datenbasis nach Aufnahmen trennen	Ganze Aufnahmen zuordnen; Training und Kalibrierung nur mit Normaldaten; Vorverarbeitung nur an Trainingsdaten anpassen
A3	M MUSS	Verfahren einheitlich vergleichen	Gleiche Testfenster und Labels; gemeinsame Kalibrierungsregel und dokumentierte Eingaben
A4	F MUSS	Automatisch und lokal auswerten	Versuchslauf ohne Cloud-Dienst; Score, Schwelle und Entscheidung je gültigem Fenster; ungültige Fenster kennzeichnen
A5	NF MUSS	Daten und Softwarestände nachvollziehbar zuordnen	Lauf, Fenster, Code, Modell, Vorverarbeitung sowie Softwareabhängigkeiten und Versionen maschinenlesbar dokumentieren
A6	M MUSS	Zielkompatibilität und ausgeführtes Modell prüfen	Modelloperationen auf der Zielhardware prüfen; bei Konvertierung Scores und Entscheidungen nach vorab festgelegten Akzeptanzgrenzen vergleichen
A7	NF MUSS	Latenzziel aus H2 erfüllen: $P99 < S/f_s$	Inferenzzeit und Verarbeitungslatenz getrennt erfassen; Latenzverteilung, Fristüberschreitungen und Erfassungspausen berichten
A8	NF MUSS	Ohne Speicherabbruch und wachsenden Rückstand laufen	Modellgröße, Prozessspeicher, CPU und Rückstand über dokumentierte Messdauer erfassen; Aufwärmphase und Hintergrundlast angeben
A9	M MUSS	Erkennungsqualität bewerten	Konfusionsmatrix, Precision, Recall, F1, Fehlalarmrate und Accuracy auf derselben Testmenge; Ergebnisse je Aufnahme
A10	M MUSS	Geänderte Normalbedingungen prüfen	Fehlalarmraten bei unveränderter Vorverarbeitung, unverändertem Modell und unveränderter Schwelle vergleichen

ID	Art / Priorität	Anforderung	Nachweis
A11	M MUSS	Reproduzierbaren Testaufbau realisieren	Aufbau und Protokoll dokumentieren; sicheren Betrieb herstellen; Normal- und Anomaliezustände wiederholen; Rücksetzbarkeit und kontrollierte Veränderung prüfen
A12	F KANN	Live-GUI zur Ergebnisanzeige entwickeln	Angezeigte Werte mit gespeicherten Ergebnissen abgleichen; veraltete und fehlende Daten prüfen; Zusatzaufwand messen
A13	F MUSS	Messläufe starten und geordnet beenden	Start und Stopp prüfen; eindeutige Laufkennung und Erhalt vollständig erfasster Daten und Ergebnisse nachweisen

Kapitel 5 leitet aus A1–A13 Kriterien für Prüfstand, Messkette, Verarbeitung und Evaluation ab. MUSS-Prioritäten sind keine Gewichte: Bekannte Nichterfüllungen dürfen nicht durch Vorteile anderer Kriterien ausgeglichen werden. Noch offene Nachweise begrenzen die Vorauswahl. Die konkrete Lösung wird erst im Variantenvergleich festgelegt.

5 Variantenvergleich und Systementscheidung

Dieses Kapitel begründet die Systemauswahl anhand der Anforderungen A1–A13 und beantwortet damit den zweiten Teil von FF1. Zunächst wird der Prüfstand ausgewählt. Darauf folgen Sensorik und Edge-Plattform, Datenrepräsentation und Verfahren sowie die Entwicklungs- und Inferenzumgebung. Die abschließende Systementscheidung verbindet diese Teilauswahlen mit den noch ausstehenden Nachweisen.

5.1 Bewertungsrahmen und Vorgehen

Die Bewertung berücksichtigt die Eignung für die Forschungsfragen, die technische Umsetzbarkeit und den erforderlichen Zusatzaufwand. Anforderungen und Auswahlgründe müssen dabei nachvollziehbar zusammenhängen (NASA, 2023). Für den Prüfstand stehen wiederholbare Zustände und kontrollierte Veränderungen im Vordergrund (A10, A11). Für die Messkette sind Signalqualität und zeitliche Erfassung entscheidend (A1). Hardware und Software müssen die lokale Verarbeitung sowie ihre überprüfbare Ausführung ermöglichen (A4–A8).

Zuerst werden die MUSS-Anforderungen geprüft. Eine bekannte Nichterfüllung kann nicht durch Punkte in anderen Kriterien ausgeglichen werden. Noch offene Nachweise, etwa zur Signalqualität oder Latenz, führen zu einer vorläufigen Auswahl mit Prüfvorbehalt. Sicherheitsmaßnahmen sind vor dem Versuch umzusetzen. Erst unter diesen Voraussetzungen werden geeignete Entwurfsvarianten gegeneinander abgewogen.

Für Prüfstand, Edge-Plattform und Software werden gewichtete Nutzwertmatrizen verwendet. Die Punkteskala reicht von 0 bis 4; ein höherer Wert bedeutet einen höheren Nutzen für dieses Projekt. Die Kriterientabellen erläutern die Bewertungsmaßstäbe. Zwischenwerte 1 und 3 kennzeichnen abgestufte Einschätzungen zwischen den beschriebenen Ankern. Gleich große Punktabstände werden vereinfachend als gleich große Nutzenzuwächse behandelt. Das ist eine Modellannahme und keine gemessene Leistungsrelation.

Die Gewichte beziehen sich auf den Unterschied zwischen dem ungünstigsten und dem günstigsten beschriebenen Zustand eines Kriteriums. Je größer dessen Bedeutung für die Forschungsfragen, desto höher wird dieser Unterschied gewichtet. Dieses Vorgehen orientiert sich am Prinzip der Swing-Gewichtung (Department for Communities and Local Government, 2009, S. 63–65). Die konkreten Gewichte und Punkte sind eigene Entwurfsannahmen; sie stammen weder aus Herstellerangaben noch aus einer Expertenbefragung. Jede Matrix wird für sich auf 100 % normiert. Nutzwerte verschiedener Auswahlbereiche sind nicht miteinander vergleichbar.

$$N_j = \sum_{i=1}^m \frac{w_i}{100} \cdot s_{ij}$$

Dabei ist m die Anzahl der Kriterien, N_j der Nutzwert der Alternative j , w_i das in Prozent angegebene Gewicht des Kriteriums i und s_{ij} dessen Punktwert. Der Nutzwert liegt zwischen

0 und 4. Er ist weder eine Erfolgswahrscheinlichkeit noch ein Nachweis erfüllter Anforderungen.

Die Sensitivität wird rechnerisch geprüft: Jedes Gewicht wird einzeln um fünf Prozentpunkte erhöht und gesenkt; die übrigen Gewichte werden proportional auf zusammen 100 % angepasst. Zusätzlich werden gleiche Gewichte und ausgewählte Änderungen unsicherer Punktwerte um einen Punkt betrachtet. Diese Prüfungen zeigen die Abhängigkeit von den Annahmen, ersetzen aber keine Messung (NASA, 2023).

5.2 Bewertung der Prüfstandsalternativen

Der Prüfstand muss normale und gezielt veränderte Zustände wiederholt herstellen können (A11). Für FF4 muss außerdem eine Normalbedingung veränderbar sein, ohne diese Änderung bereits als Anomalie zu kennzeichnen (A10). Tabelle 5-1 vergleicht hierfür drei Alternativen anhand ihrer Kontrollierbarkeit, des zusätzlichen Aufwands und ihrer Aussagegrenzen.

Tabelle 5-1: Bewertung der Prüfstandsalternativen

Alternative	Kontrollierbarkeit und Wiederholung	Zusatzaufwand und Aussagegrenze
Lüfter mit PWM-Ansteuerung	Betriebspunkte vorgebar; Versuchszustände bei fester Montage wiederholbar zu gestalten	Wenige Antriebskomponenten; Lastvariation und Übertragbarkeit auf Industriemaschinen begrenzt
Servomotor mit Regler	Geregelte Drehzahl- und Bewegungsprofile; Lastvariation mit zusätzlicher Belastungseinrichtung	Regler, mechanische Kopplung und gegebenenfalls Lastmaschine nötig; Regelung beeinflusst das Schwingungsverhalten
Motor-/ Lagerprüfstand	Drehzahl, Last und Lagerzustände gezielt untersuchbar	Zusätzliche Mechanik, Messtechnik und Schutzmaßnahmen; größere Nähe zur Lagerdiagnostik

Quelle: Eigene Bewertung auf Grundlage von ARCTIC (o. J.), Oriental Motor (o. J.) und Universität Paderborn (o. J.). Der Aufwand ist eine qualitative Einschätzung der benötigten Komponenten.

Für die Bewertung wird vorausgesetzt, dass bei allen drei Varianten sichere, rücksetzbare Versuchszustände realisiert werden können. Dies bleibt nach A10 und A11 am fertigen Aufbau nachzuweisen. Die folgenden Kriterien unterscheiden die verbleibenden Gestaltungsmöglichkeiten. Der Realisierungsaufwand erhält das größte Gewicht, weil die Arbeit den Methodenvergleich und keine Entwicklung einer komplexen Antriebsanlage untersucht. Es werden benötigte Baugruppen eingeschätzt; Kosten oder Arbeitsstunden werden nicht behauptet.

Tabelle 5-2: Kriterien und Gewichte für den Prüfstand

Kriterium	Gewicht	Bewertungsmaßstab und Anforderungsbezug
P1 Betriebspunkte einstellen	25 %	A10, A11. 0: keine Vorgabe; 2: einzelne Stellgröße ohne unabhängige Lastregelung; 4: geregelte Drehzahl und zusätzlich Last oder Bewegung vorgebar.
P2 Einflüsse trennen	25 %	A10, A11. 0: Änderungen nicht zuordenbar; 2: mehrere gekoppelte Einflüsse; 4: einfache Variation bei fester Mechanik und wenigen Einflussgrößen.
P3 Aufbauaufwand	40 %	A11. 0: im Projekt nicht realisierbar; 2: Antrieb, Regler und Kopplung aufzubauen; 4: integrierter Antrieb mit wenigen Zusatzbaugruppen.
P4 Anwendungsnähe	10 %	FF1, FF4. 0: kein rotierendes System; 2: einfache rotierende Baugruppe; 4: gezielt untersuchbare Maschinen- und Lagerzustände.

Quelle: Eigene Kriterien und Gewichte, abgeleitet aus Kapitel 4. Maßstäbe beschreiben projektbezogene Präferenzen.

Tabelle 5-3: Gewichtete Bewertung der Prüfstandsalternativen

Alternative	P1	P2	P3	P4	Nutzwert
Lüfter mit PWM	2	4	4	2	3,30
Servomotor mit Regler	4	3	2	3	2,85
Motor-/Lagerprüfstand	4	3	1	4	2,55

Quelle: Eigene Punktvergabe auf Grundlage des Variantenvergleichs und der vorausgehenden Kriterien; keine experimentellen Messwerte.

Der Lüfter erhält weniger Punkte bei der Betriebspunktregelung und der Nähe zur Maschinenüberwachung, bietet aber einen einfachen Aufbau mit wenigen zu kontrollierenden Einflussgrößen. Beim Servo kommen Rückführung und mechanische Kopplung hinzu. Der Motor-/Lagerprüfstand ermöglicht die gezielteste Lageruntersuchung, benötigt jedoch zusätzliche Belastungs- und Messbaugruppen. Die Punkte bewerten diese angenommenen Aufbauvarianten; sie belegen keine schlechtere Reproduzierbarkeit eines professionellen Prüfstands.

Unter den gewählten Gewichten wird der Lüfter mit 3,30 Punkten bevorzugt. Beispielhaft ergibt sich $0,25 \cdot 2 + 0,25 \cdot 4 + 0,40 \cdot 4 + 0,10 \cdot 2 = 3,30$. In den acht einzelnen Gewichtsänderungen bleibt er vorn. Bei gleichen Gewichten erreichen dagegen alle Varianten 3,00 Punkte. Die Auswahl hängt damit wesentlich vom begrenzten Realisierungsaufwand ab. Eine einzelne Änderung eines Punktwerts um einen Punkt kehrt die Ausgangsrangfolge an der Spitze nicht um; gemeinsame Änderungen können dies tun.

Für den Kernversuch wird deshalb der Lüfter gewählt. Ein Servomotor wäre bei Lastwechseln oder dynamischen Bewegungsprofilen sinnvoll, ein Motor-/Lagerprüfstand bei konkreten Lagerfehlern. Diese Aufgaben gehören nicht zum Kernvergleich. Die Ergebnisse bleiben auf den untersuchten Laborversuch begrenzt.

Als konkrete Variante wird der ARCTIC P12 Pro PST vorgesehen, dessen Datenblatt PWM-Ansteuerung und ein Drehzahlsignal ausweist (ARCTIC, o. J.). Ein PWM-Tastgrad ist eine Stellgröße und kein Nachweis einer konstanten Drehzahl; die tatsächliche Drehzahl ist zu erfassen. Für FF4 wird ein zweiter normaler Betriebspunkt bei unveränderter Montage untersucht. Art und Rücksetzbarkeit der Versuchsanomalien, Schutzmaßnahmen und Messablauf werden in Kapitel 6 vor der abschließenden Testserie festgelegt.

5.3 Auswahl von Sensorik und Edge-Plattform

Die Sensorik muss die vorgesehenen dreiachsigen Beschleunigungssignale mit ausreichender Qualität erfassen. Verglichen werden zwei digital anschließbare MEMS-Sensoren und eine industrielle Messkette. Tabelle 5-4 nennt Eigenschaften, die für A1 relevant sind. Datenblattwerte belegen noch keine ausreichende Signalqualität am späteren Montageort.

Tabelle 5-4: Vergleich der Sensorik und Messketten

Alternative	Relevante Herstellerangaben	Bewertung für den Prüfstand
ADXL345	Drei Achsen; $\pm 2/4/8/16$ g; I ² C/SPI; FIFO	Direkte digitale Erfassung; Bandbreite, Auflösung und Rauschen am Aufbau prüfen
ADXL355	Drei Achsen; $\pm 2/4/8$ g; 20-Bit-ADC; typische Rauschdichte $22,5 \mu\text{g}/\sqrt{\text{Hz}}$ bei ± 2 g	Alternative bei höheren Anforderungen an Auflösung und Rauschen; eigene Integrationsprüfung nötig
PCB 356A32 mit IEPE-Messkette	Drei Achsen; ± 50 g; 100 mV/g ; 1–4000 Hz innerhalb ± 5 %	Größerer spezifizierter Frequenzbereich; Konstantstromspeisung und externe A/D-Wandlung nötig

Quelle: Eigene Einordnung nach Analog Devices (2022, 2025) und PCB Piezotronics (o. J.). Die Zahlen sind Herstellerangaben.

Für den ersten Systementwurf wird der ADXL345 mit digitaler I²C-Anbindung vorgesehen. Er bietet eine vollständige dreiachsige Messung ohne externe A/D-Wandlung. Auch der ADXL355 erfüllt dieses Integrationsprinzip; die Wahl des ADXL345 ist daher eine zu prüfende Ausgangsentscheidung und kein Nachweis seiner Überlegenheit. Reichen Auflösung oder Signal-Rausch-Abstand nicht aus, wird der ADXL355 als Alternative geprüft. Eine IEPE-Messkette ist erst bei entsprechendem Bandbreiten- oder Messqualitätsbedarf zu rechtfertigen.

Die Pilotmessung prüft effektive Erfassungsrate, neue Sensorwerte, Datenlücken, Sättigung und den Abstand des Nutzsignals zum Rauschboden bei dokumentierter Montage (A1). Die Akzeptanzgrenzen sind vor der abschließenden Testserie festzulegen. Beim ADXL345 beträgt die maximal empfohlene Sensorausgaberate bei 400-kHz-I²C 800 Hz; bei 100-kHz-I²C sind es 200 Hz. Diese Grenzen ersetzen keine Messung der tatsächlich erreichten Erfassung (Analog Devices, 2022, S. 17).

Die Edge-Plattform muss neben der Inferenz auch Datenerfassung, Vorverarbeitung, Baselines und Messwerkzeuge tragen (A4, A7, A8). Tabelle 5-5 vergleicht deshalb den

Ressourcenrahmen und die daraus abgeleiteten Integrationsfolgen. Taktraten und Beschleunigerangaben erlauben keinen unmittelbaren Vergleich der Inferenzzeiten.

Tabelle 5-5: Bewertung der Edge-Plattformen

Alternative	Dokumentierter Ressourcenrahmen	Bewertung für den Methodenvergleich
STM32H743	Cortex-M7 bis 480 MHz; bis 2 MB Flash und 1 MB RAM	Hardwarenahe Umsetzung möglich; knapper Speicher und eigenständige Portierung der Pipeline
Raspberry Pi 4 Model B	Vier Cortex-A72-Kerne mit 1,8 GHz; RAM im GB-Bereich	Plausible Linux-Plattform für CPU-Inferenz und Messwerkzeuge
Raspberry Pi 5	Vier Cortex-A76-Kerne mit 2,4 GHz; RAM im GB-Bereich	Nominell größere CPU-Reserve; konkrete Latenz und Speicherbelegung bleiben zu messen
Jetson Orin Nano Super	Sechs Cortex-A78AE-Kerne; 8 GB RAM; GPU-Beschleunigung	Sinnvoll bei GPU-bedürftigen Modellen; Nutzen für den vorgesehenen CPU-Vergleich nicht belegt

Quelle: Eigene Bewertung nach STMicroelectronics (2026), Raspberry Pi Ltd. (o. J., 2026) und NVIDIA (o. J.).

Die Ressourcenangaben werden nicht in erwartete Inferenzzeiten umgerechnet. Die gewichtete Vorauswahl verbindet den nominellen Ressourcenrahmen mit der Integration der vollständigen Pipeline. Das Gewicht für zeitliche Kontrollierbarkeit bleibt begrenzt, weil H2 ein empirisches Latenzziel und keine harte Echtzeitgarantie formuliert.

Tabelle 5-6: Kriterien und Gewichte für die Edge-Plattform

Kriterium	Gewicht	Bewertungsmaßstab und Anforderungsbezug
E1 Nomineller Ressourcenrahmen	35 %	A8. 0: keine plausible Reserve; 2: eingeschränkter Rahmen; 4: GB-Arbeitsspeicher und größere nominelle CPU-Reserve im Variantenfeld. Kein Laufzeitnachweis.
E2 Integration der Gesamtpipeline	35 %	A4–A6. 0: keine geeignete Umgebung; 2: erhebliche Anpassungen; 4: allgemeine Linux-/Python-Umgebung für Erfassung, Verfahren und Messwerkzeuge.
E3 Zeitliche Kontrollierbarkeit	15 %	A7. 0: Ablauf kaum beeinflussbar; 2: allgemeines Betriebssystem mit schwankender Last; 4: hardwarenah planbare Ausführung. Keine Fristgarantie.
E4 Passung zum CPU-Kernvergleich	15 %	FF1, FF3. 0: ungeeignete Plattformklasse; 2: zusätzliche Beschleuniger bleiben ungenutzt oder die Plattform erzwingt einen Portierungsfokus; 4: CPU-System ohne solche Zusatzschwerpunkte.

Quelle: Eigene Kriterien und Gewichte aus Kapitel 4. Ressourcen, Softwareintegration, Zeitplanung und Untersuchungsumfang werden getrennt betrachtet.

Tabelle 5-7: Gewichtete Bewertung der Edge-Plattformen

Alternative	E1	E2	E3	E4	Nutzwert
STM32H743	1	1	4	2	1,60
Raspberry Pi 4	3	4	2	4	3,35

Alternative	E1	E2	E3	E4	Nutzwert
Raspberry Pi 5	4	4	2	4	3,70
Jetson Orin Nano Super	4	4	2	2	3,40

Quelle: Eigene Punktwertung nach dem dokumentierten Ressourcenrahmen und den Kriterien E1-E4; keine gemessenen Leistungswerte.

Der STM32 wird bei Ressourcen und Integration wegen des begrenzten Speichers und der notwendigen Portierung niedrig bewertet. Die Linux-Plattformen erhalten bei der allgemeinen Integration denselben Wert. Der Pi 4 erhält für E1 einen Punkt weniger als der Pi 5; dies bewertet ausschließlich die nominelle CPU-Reserve. Die Jetson-GPU bringt für den hier abgegrenzten CPU-Vergleich keinen zusätzlichen Untersuchungsnutzen. Ihre Leistungsfähigkeit wird damit nicht infrage gestellt.

Der Raspberry Pi 5 erreicht 3,70 Punkte und wird als Zielplattform gewählt. Er bleibt bei den acht einzelnen Gewichtsänderungen und bei gleichen Gewichten vorn. Die Einschätzung ist jedoch punktempfindlich: Wird seine Ressourcenbewertung E1 um einen Punkt gesenkt, liegt er mit 3,35 gleichauf mit dem Pi 4 und unter dem Jetson mit 3,40. Die nominelle Reserve ist deshalb eine Entwurfsbegründung, kein Leistungsbeleg. Die Erfüllung von A7 und A8 wird an der vollständigen Pipeline gemessen; ein zusätzlicher Hardwarebenchmark gehört nicht zum Kernversuch.

5.4 Datenbasis, Signalrepräsentation und Verfahren

Für die Evaluation werden eigene reale Messläufe gewählt. Damit umfasst die Untersuchung die vollständige Kette vom Sensor bis zur Entscheidung. Öffentliche Datensätze können die Methodenentwicklung unterstützen, ersetzen jedoch keinen Nachweis an der gewählten Messkette. Simulierte Daten eignen sich für Funktionstests, belegen aber keine Erkennungsleistung am realen Prüfstand. Ganze Aufnahmen werden nach A2 getrennt zugeordnet. Training und Schwellenwertkalibrierung verwenden ausschließlich Normaldaten.

Tabelle 5-8: Bewertung der Signalrepräsentationen

Darstellung	Informationsgehalt und Grenze	Vorgesehene Rolle
Dreiaxsiges Zeitfenster	Erhält Reihenfolge und Achsenbeziehungen; höhere Eingabedimension	Gemeinsame Ausgangsdaten für den Hauptvergleich
Zeitbereichskennwerte	Kompakt und interpretierbar; zeitliche Struktur wird verdichtet	RMS als statistische Baseline
Frequenzspektrum mittels FFT	Zeigt Frequenzanteile; abhängig von Abtastung, Fensterdauer und Fensterfunktion	Ergänzende Analyse gespeicherter Pilotmessungen

Darstellung	Informationsgehalt und Grenze	Vorgesehene Rolle
Zeit-Frequenz-Darstellung	Zeigt zeitlich wechselnde Frequenzanteile; zusätzliche Parameter und Rechenaufwand	Keine zusätzliche Variante im Kernvergleich

Quelle: Eigene Einordnung auf Grundlage von Ruff et al. (2021) und SciPy developers (o. J. a, o. J. b).

Die Fast Fourier Transform (FFT) ist ein effizienter Algorithmus zur Berechnung der diskreten Fourier-Transformation. Sie wird ergänzend eingesetzt, um beobachtbare Frequenzanteile in Pilotmessungen zu untersuchen und die Wahl von Erfassungsrate und Fensterdauer zu unterstützen. Für H gleichmäßig abgetastete Werte beträgt der Abstand der Frequenzstützstellen $\Delta f = f_s/H$; dies allein beschreibt noch nicht die Trennbarkeit benachbarter Frequenzanteile (SciPy developers, o. J. a, o. J. b).

Eine FFT behebt weder Datenlücken noch Aliasing. Vor ihrer Auswertung müssen zeitliche Regelmäßigkeit, nutzbare Sensorbandbreite und mögliche Frequenzüberlagerungen durch die Abtastung geprüft werden. Mittelwertbehandlung, Fensterfunktion und Amplitudenskalierung sind zu dokumentieren. Die Spektralanalyse erfolgt ergänzend außerhalb der Live-Pipeline. FFT-Merkmale würden eine weitere Verfahrensvariante bilden und müssten vor der Testauswertung festgelegt sowie mit ihrem Zusatzaufwand bewertet werden. Die FFT selbst liefert keine Anomalieentscheidung.

Tabelle 5-9: Auswahl der Anomalieverfahren

Verfahren	Rolle und Auswahlgrund	Wesentliche Grenze
Autoencoder	Neuronales Hauptverfahren; prüft den Nutzen einer erlernten multivariaten Rekonstruktion	Eine gute Trennung der Zustände ist empirisch zu prüfen
RMS mit Schwelle	Statistische Minimalbaseline; transparente Verdichtung auf einen Kennwert	Verwirft die zeitliche Reihenfolge
Isolation Forest	Klassische Lernbaseline; ergänzt den RMS um eine multivariate Bewertung	Nutzt keine explizite zeitliche Nachbarschaft
One-Class SVM	Plausible Alternative zur klassischen Lernbaseline	Zusätzliche Kernel- und Hyperparameterwahl; keine weitere Vergleichsrolle
Überwachte Klassifikation	Geeignet bei repräsentativen gelabelten Fehlerklassen	Benötigt Fehlerbeispiele im Training und passt damit nicht zum gewählten Szenario

Quelle: Eigene Rollenverteilung nach Liu et al. (2008), Ruff et al. (2021) und scikit-learn developers (o. J. d).

Der Hauptvergleich umfasst Autoencoder, RMS und Isolation Forest. So werden die in Kapitel 1 festgelegten drei Verfahrensklassen abgedeckt. Alle erhalten dieselben $H \times 3$ -Ausgangsfenster. Die Standardisierung wird ausschließlich an Trainingsdaten angepasst. Der Autoencoder rekonstruiert das standardisierte Fenster, der Isolation Forest verwendet dessen Werte in fester Reihenfolge als Vektor. Die RMS-Baseline berechnet einen

gemeinsamen Effektivwert über alle 3H standardisierten Werte; dieser Score ist dimensionslos und vom RMS der Beschleunigung in g zu unterscheiden.

Für jedes Verfahren wird die Schwelle als empirisches 99. Perzentil seiner Scores auf separaten normalen Validierungsaufnahmen bestimmt. Größere Scores bedeuten stets eine stärkere Auffälligkeit. Die genaue Quantilsberechnung, Modellparameter und Fensterbildung werden vor der Testauswertung festgehalten (A2, A3). Eine bessere Erkennungsqualität des Autoencoders wird damit nicht vorausgesetzt, sondern durch H1 geprüft.

5.5 Kriterienbasierte Bewertung der Softwarealternativen

Die Softwareauswahl betrifft den Entwicklungs- und Ausführungspfad des Autoencoders. TensorFlow/Keras und PyTorch dienen zur Modellbildung; TFLite/LiteRT, ExecuTorch und ONNX Runtime bieten Wege zur lokalen Inferenz. Der Prüfstand wurde bereits in Abschnitt 5.2 bewertet. Die nachfolgenden Kriterien betreffen die Software und werden aus A4–A8 abgeleitet.

Tabelle 5-10: Kriterienbasierter Vergleich der Softwarealternativen

Entwicklungs- und Ausführungspfad	Übergang zur Inferenz	Lokale Ausführung	Integrations- und Prüfaufwand
TensorFlow/Keras → TFLite/LiteRT	Dokumentierter Konverter für Keras-Modelle; .tflite-Datei	CPU-Inferenz mit passender Laufzeit	Modelloperationen, Paketkompatibilität und Konvertierung prüfen
PyTorch → ExecuTorch	Modellexport und Anpassung an ein Backend; .pte-Datei	Arm-CPU über geeignetes Backend, z. B. XNNPACK	Export, Backend und numerische Übereinstimmung prüfen
PyTorch → ONNX Runtime	Export in das ONNX-Austauschformat	CPU-Paket für Linux ARM64	Exporter, ONNX-Operatorversionen und Laufzeit abstimmen
TensorFlow/Keras → TensorFlow direkt	Kein Wechsel des Modellformats erforderlich	TensorFlow-CPU-Paket für Linux ARM64	Paketkompatibilität und Ressourcenbedarf der vollständigen Umgebung prüfen

Quelle: Eigene Bewertung nach Google (2026a, 2026c, 2026d), PyTorch (o. J.) und ONNX Runtime developers (o. J.). Die Zielkompatibilität des konkreten Modells ist bei jeder Alternative zu prüfen.

Die gemeinsame Voraussetzung ist, dass Modelloperationen, Python-Version und Betriebssystem auf dem Zielgerät zusammenpassen (A6). Dies ist für das konkrete Modell noch nachzuweisen. Dokumentierte ARM64-Unterstützung allein bestätigt keine beliebige Raspberry-Pi-OS-Konfiguration. Für TFLite wird ein separates Interpreter-Paket beschrieben; Modelle mit zusätzlichen TensorFlow-Operationen können eine umfangreichere Umgebung benötigen (Google, 2026c). Diese Einschränkung wird bei der Modellkonvertierung geprüft.

Tabelle 5-11: Kriterien und Gewichte für die Softwareauswahl

Kriterium	Gewicht	Bewertungsmaßstab und Anforderungsbezug
S1 Entwicklung und Inferenz trennen	30 %	A5, A8. 0: kein getrennt ladbares Modell; 2: gespeichertes Modell benötigt vollständiges Framework; 4: separates Inferenzpaket vorgesehen.
S2 Modellübergang nachvollziehen	25 %	A5, A6. 0: kein dokumentierter Weg; 2: nur teilweise dokumentiert; 4: offizieller Weg zum Speichern bzw. Exportieren und Laden.
S3 Python-Anbindung	25 %	A4, A5. 0: keine Anbindung; 2: eigene Brücke nötig; 4: offiziell dokumentierte Python-API.
S4 Linux-ARM64-CPU unterstützen	20 %	A4, A6. 0: kein dokumentierter Weg; 2: eigene Portierung nötig; 4: dokumentiertes CPU-Paket für Linux ARM64. Konkrete Versionen bleiben zu prüfen.

Quelle: Eigene Kriterien und Gewichte aus Kapitel 4. Die Punkte bewerten dokumentierte Wege, nicht deren gemessenen Ressourcenbedarf.

Tabelle 5-12: Gewichtete Bewertung der Softwarealternativen

Entwicklungs- und Ausführungspfad	S1	S2	S3	S4	Nutzwert
TensorFlow/Keras → TFLite/LiteRT	4	4	4	4	4,00
PyTorch → ExecuTorch	4	4	4	4	4,00
PyTorch → ONNX Runtime	4	4	4	4	4,00
TensorFlow/Keras → TensorFlow direkt	2	4	4	4	3,40

Quelle: Eigene Bewertung der offiziellen Dokumentation von Google (2026a, 2026c, 2026d), PyTorch (o. J.) und ONNX Runtime developers (o. J.).

Die drei separaten Inferenzwege erreichen jeweils 4,00 Punkte. Sie bieten die in S1–S4 beschriebenen Möglichkeiten. Die direkte TensorFlow-Ausführung erhält bei S1 zwei Punkte, weil dabei das vollständige Framework vorgesehen ist; dafür entfällt der Formatwechsel. Eine hohe Punktzahl sagt nichts über spätere Latenz, Speichernutzung oder Erkennungsqualität aus. Diese Größen werden nicht mit unbelegten Schätzwerten bewertet.

Der Gleichstand bleibt bei gleichen Gewichten und bei allen acht einzelnen Gewichtsänderungen bestehen. Sinkt ein bisher mit vier Punkten bewertetes Kriterium einer Alternative um einen Punkt, verliert diese ihren Gleichstand an der Spitze. Die Matrix zeigt daher mehrere geeignete Wege und keinen eindeutigen TensorFlow-Vorsprung. Bei gleich geeigneten Alternativen ist eine begründete Entwurfsentscheidung zulässig (NASA, 2023).

Für diese Arbeit wird aus dieser Gruppe TensorFlow/Keras mit einem Float32-TFLite-Modell gewählt. Der dokumentierte direkte Konverter für Keras-Modelle ermöglicht einen klaren Weg von der Modellbildung zur gespeicherten Inferenzdatei und deren Prüfung gegen das Ausgangsmodell (Google, 2026a). Damit wird eine konkrete Umsetzung innerhalb der gleich

bewerteten Gruppe festgelegt. ExecuTorch bleibt eine gleichwertige Entwurfsalternative nach den verwendeten Maßstäben; ONNX Runtime wäre besonders bei einem gewünschten Austauschformat zweckmäßig. Ein solcher Austausch ist keine eigene Anforderung des Kernversuchs.

Im Hauptvergleich wird auf Quantisierung verzichtet. So wird zunächst keine zusätzliche Änderung der Zahlendarstellung untersucht. Die Dokumentation empfiehlt ein nicht quantisiertes TFLite-Modell als Ausgangspunkt für die Kompatibilitätsprüfung (Google, 2026b). Ob die ausgewählte Laufzeit A7 und A8 erfüllt, entscheidet erst die Messung. Auch eine kleine Modelldatei garantiert keinen kleinen Prozessspeicher. Konkrete Pakete, Versionen und ihre Einbindung werden in Kapitel 6 dokumentiert.

5.6 Systementscheidung und Übergang zur Implementierung

Die abschließende Tabelle fasst die Entscheidungen und die jeweils noch erforderlichen Nachweise zusammen. Die Nutzwerte unterstützen die Auswahl innerhalb des jeweiligen Variantenfelds. Sie sind an die offengelegten Gewichte, Punkte und Prüfvorbehalte gebunden. Die praktische Eignung bleibt Gegenstand von Implementierung und Evaluation.

Tabelle 5-13: Systementscheidungen und ausstehende Nachweise

Bereich	Auswahl	Anforderungsbezug und Nachweis
Prüfstand	Lüfter mit PWM; 3,30 Punkte	A10, A11: wiederholbare Zustände und zweiter normaler Betriebspunkt
Sensorik	ADXL345 als Ausgangsvariante; ADXL355 als Alternative	A1: Signalqualität und zeitliche Erfassung vor der Testserie prüfen
Edge-Plattform	Raspberry Pi 5; 3,70 Punkte	A4, A7, A8: vollständige Pipeline und Zeitbudget messen
Datenbasis	Eigene reale Messläufe; Normaldaten für Training und Kalibrierung	A2, A3, A9: getrennte Aufnahmen und gemeinsame Testbasis
Verfahren	Autoencoder, RMS und Isolation Forest	A3, A9: gleiche Fenster und Kalibrierungsregel; Erkennungsqualität vergleichen
FFT	Ergänzende Analyse der Pilotmessungen	A1: Frequenzanteile innerhalb der überprüften Messbandbreite untersuchen
Neuronale Software	TensorFlow/Keras → Float32-TFLite; 4,00 Punkte, Gleichstand mit zwei Alternativen	A5–A8: Konvertierung, Zielkompatibilität und Ressourcen prüfen
Bedienung und Ausgabe	Start/Stop und gespeicherte Ergebnisse; Live-GUI optional	A4, A5, A12, A13: Datenzuordnung, geordnetes Beenden und gegebenenfalls Anzeige prüfen

Quelle: Eigene Zusammenführung der Entscheidungen aus den Abschnitten 5.2–5.5.

Kapitel 6 dokumentiert Aufbau, Software, Eignungsprüfungen und das vor der Testauswertung festgelegte Versuchsprotokoll. Entwicklungsaufnahmen bleiben explorativ;

eine unabhängige Bestätigung benötigt neue Testaufnahmen gemäß Abschnitt 1.4. Kapitel 7 bewertet Anforderungen und Hypothesen. Nicht bestätigte Hypothesen werden berichtet; eine nachträgliche Anpassung an die Testdaten ist ausgeschlossen.

6 Implementierung

Dieses Kapitel beschreibt den am 12. September 2026 belegten Stand der lokalen Mess- und Verarbeitungskette. Die Anforderungen aus Kapitel 4 und die Vorauswahl aus Kapitel 5 werden in konkrete Komponenten, Datenregeln und Prüfungen übersetzt. Maßgeblich ist das eingefrorene Pilotpaket für Aufbau v4. Implementierte Funktionen, experimentelle Ergebnisse und verbleibende Nachweislücken werden getrennt behandelt. Die Ergebnisse stehen in Kapitel 7; die Reproduktionsunterlagen sind im Anhang zugeordnet.

6.1 Prüfstand, Aufbauversionen und Zustandsnachweise

Der Prüfstand besteht aus einem Raspberry Pi 5, einem über I²C angeschlossenen ADXL345 und einem ARCTIC P12 Pro PST mit externer 12-V-Versorgung. Der Sensor ist nach Nutzerangabe mit zwei Schrauben an einer Ecke des äußeren, feststehenden Lüfterrahmens befestigt. Seine Platine steht schräg. Die endgültig untersuchte Aufstellung v4 ist aufrecht; die sichere Befestigung und die Rotorfreiheit wurden vom Nutzer geprüft. Eine metrische Vermessung der Sensororientierung und der gesamten mechanischen Übertragungsstrecke liegt nicht vor. Aus einer festen Befestigung allein wird keine ausreichende Messqualität abgeleitet.

Während der Entwicklung wurden Sensorbefestigung und Lüfteraufstellung verändert. Jede solche Änderung erhielt eine eigene Aufbauversion. Frühere liegende Aufnahmen und die zuvor aufrechte, später noch verschobene Position werden deshalb nicht mit v4 zu einer Normalreferenz zusammengeführt. Die verbindliche Aufbaukennung lautet fan_upright_position_v4_20260911_103726. Training, Kalibrierung und die hier bewerteten unabhängigen Versuche gehören ausschließlich zu dieser Version. Bei einer weiteren mechanischen Änderung wäre die Übertragbarkeit neu zu prüfen.

Eine nachträgliche Nutzerangabe erläutert, dass der Lüfter während eines früheren Arbeitsdurchlaufs ausgeschaltet war. Außerdem sei eine damalige PWM-Vorgabe halbiert worden. Die genauen historischen Ausgangs- und Zielwerte bleiben unbekannt. Diese Aussage ergänzt die Arbeitsdokumentation, verändert aber keine ursprünglichen Messprotokolle. Sie macht frühere Aufnahmen ohne zeitgleiche Bestätigung von Auslauf und Messbedingungen nicht nachträglich zu kontrollierten Stillstandsreferenzen.

Tabelle 6-1: Prüfstand und Bedeutung der dokumentierten Größen

Bestandteil	Belegter Stand	Aussagegrenze
Zielrechner	Raspberry Pi 5, ARM64, vier CPU-Kerne; lokale Python-Ausführung	Keine Messung an Mikrocontrollern oder anderer Edge-Hardware
Prüflüfter	ARCTIC P12 Pro PST, externe 12-V-Versorgung	Versorgung angeschlossen nach Nutzerangabe; Spannung nicht kontinuierlich gemessen
Sensor und Montage	ADXL345, zwei Schrauben am äußeren Lüfterrahmen, Platine schräg; aufrechter Aufbau v4	Orientierung und mechanische Übertragungsfunktion nicht kalibriert
Stellanschluss	BCM-GPIO18, physischer Pin 12; Hardware-PWM	Rückgelesene Einstellung ist keine elektrische Signal- oder Drehzahlmessung

Bestandteil	Belegter Stand	Aussagegrenze
Primärer Betriebspunkt	75 % Tastgrad, 25 kHz	Keine gemessene konstante Drehzahl
Zweiter Normalbetriebspunkt	50 % Tastgrad, 25 kHz; Aufbau unverändert	Normalbedingung; kein Fehlerlabel
Plattenzustand	Separate Platte, 120 × 120 mm, 100 mm vor dem Luftauslass, parallel ausgerichtet	Geometrie aus Nutzerangaben; keine Luftstrom- oder Druckmessung
Drehzahlerfassung	Kein eindeutig bestätigter separater Tachoeingang; RPM-Feld bleibt leer	Der in Kapitel 5 vorgesehene Drehzahlnachweis ist nicht erfüllt

Die tatsächliche Plattenbreite von 120 mm weicht vom frühen Vorschlag einer 60 × 120 mm großen Platte ab. Für die abgeschlossene v4-Folge gilt die später dokumentierte Istgeometrie. Die Platte war separat befestigt und berührte nach Nutzerangabe weder Lüfter noch Sensor. Der veränderte Luftstrom wird als kontrolliert veränderter Betriebszustand bezeichnet. Ein Defekt des Lüfters wurde damit weder erzeugt noch nachgewiesen.

6.2 Hardware-PWM und Ablaufsteuerung

Der verwendete Anschluss wird in BCM-Nummerierung angegeben: GPIO18 liegt am physischen Pin 12. Der physische Pin 18 gehört zu GPIO24. Der während der Entwicklung verwendete Befehl `pinctrl set 18 op dh` stellt GPIO18 auf einen gewöhnlichen Digitalausgang mit High-Pegel. Für Zwischenwerte wurde die vorhandene Hardware-PWM-Funktion wiederhergestellt. Sie erscheint auf GPIO18 als Funktion `a3` mit der Bezeichnung `PWM0_CHAN2`. Der zugehörige Linux-Pfad ist `pwmchip0/pwm2` am RP1-Controller.

Bei 25 kHz beträgt die Periodendauer 40.000 ns. Eine Vorgabe von 75 % entspricht einer Tastzeit von 30.000 ns; 50 % entspricht 20.000 ns. Bei 0 % wird eine Tastzeit von 0 ns bei weiterhin aktiviertem PWM-Kanal gesetzt. Das Modul `fan_pwm.py` prüft Gerätezuordnung, Kanal, Periode, Polarität und Pin-Funktion. Jeder Stellbefehl erhält monotone Zeitstempel, UTC-Zeit und eine Rücklesung. Das Öffnen und Schließen des Steuerkontexts allein verändert die Stellvorgabe nicht; die Rückstellung erfolgt ausdrücklich im Abschlusszweig des Messprogramms.

Ein exklusiver Prozess-Lock koordiniert Programme, die diesen Steuerweg verwenden. Vor Hardwareläufen werden zusätzlich mögliche konkurrierende Steuer- und Sensorprozesse geprüft. Fremde Programme können diese Sperre umgehen; der Lock ist deshalb kein elektrischer Verriegelungsmechanismus. Die Messläufe halten die vorgegebene PWM konstant. Modellentscheidungen verändern sie während des Methodenvergleichs nicht. Damit hängt der beobachtete Betriebszustand nicht von dem jeweils untersuchten Verfahren ab.

Nach jedem Betriebsversuch wird 0 % angefordert und zurückgelesen. Auch bei einem Erfassungsfehler oder einer Unterbrechung wird dieser Abschluss nach Möglichkeit ausgeführt. Ein misslungener Stellbefehl führt zu einem Fehlerstatus. Es erfolgt kein automatischer Wiederholungsstart. Softwaretests prüfen diese Pfade einschließlich

Erfassungsfehler und Programmabbruch; reale Stelljournale dokumentieren die tatsächlich ausgeführten Befehle. Vollständiger mechanischer Stillstand wird nur dort als bestätigt bezeichnet, wo eine entsprechende Nutzerbeobachtung vorliegt. Die Herstellerangabe zum 0-rpm-Betrieb ersetzt diese Beobachtung nicht (ARCTIC, o. J.).

Die manuell begleiteten Versuche warten an den Umbaugrenzen auf eine ausdrückliche Freigabe. Der Nutzer trennt vor einem Plattenumbau die externe Versorgung und wartet den Auslauf ab. Nach der später erteilten Erlaubnis zum unbeaufsichtigten Softwarebetrieb wurden die festgelegten Normal- und Laufzeitfolgen ohne zusätzliche Chatabfragen ausgeführt. Hier wird die softwareseitige Auszeit dokumentiert; eine neue Sichtbestätigung für jeden automatischen Start wird nicht behauptet.

6.3 Sensorerfassung, Zeitbasis und Qualitätskennzeichnung

Die frühere Software fragte Ausgaberegister ab, ohne die interne Sensorausgaberate und den Messbereich für jede Aufnahme vollständig zu dokumentieren. Eine damalige Schleifenfrequenz von 500 Abfragen pro Sekunde belegt daher keine 500 neuen XYZ-Messungen pro Sekunde. Der korrigierte Erfassungsweg konfiguriert den Sensor ausdrücklich und liest die Register zurück. Er verwendet den FIFO im Stream-Modus und übernimmt vollständige XYZ-Datensätze aus dem Sensorpuffer. Häufigere Host-Abfragen allein erzeugen keine zusätzlichen Sensormessungen.

Tabelle 6-2: Unveränderte Sensorkonfiguration der v4-Messkette

Parameter	Einstellung bzw. Rücklesung	Bedeutung
Schnittstelle	I ² C-Bus 1; konfigurierter Bustakt 100 kHz	Keine elektrische Messung der SCL-Taktfrequenz
Nominelle ODR	200 Hz; Register BW_RATE = 0x0B	Sollwert der Sensorausgaberate
Messbereich	±2 g; DATA_FORMAT = 0x08	Full-Resolution-Modus
Umrechnung	0,0039 g je LSB	Nomineller Faktor; keine eigene Empfindlichkeitskalibrierung
Betriebsmodus	POWER_CTL = 0x08	Messbetrieb
FIFO	FIFO_CTL = 0x90	Stream-Modus mit konfiguriertem Schwellwert
Interruptfreigabe	INT_ENABLE = 0x00	Gepollte FIFO-Erfassung
Zeitstempel	Monotone Host-Zeit nach dem XYZ-Lesevorgang	Kein Zeitstempel der physikalischen Wandlung

Die 200-Hz-Konfiguration entspricht der im ADXL345-Datenblatt empfohlenen maximalen ODR bei 100-kHz-I²C. Sie ist eine begründete Obergrenze für diese Buskonfiguration, jedoch kein Nachweis einer ausreichenden Bandbreite für beliebige Schäden (Analog Devices, 2022, S. 17). Der Messbereich ±2 g wird im Full-Resolution-Modus mit dem nominellen Faktor 0,0039 g je LSB verwendet; Sättigung wird in jedem Lauf überprüft. Die Einstellungen wurden für v4 eingefroren, obwohl die vollständige physikalische Charakterisierung der Messkette nicht abgeschlossen war. Das Modellpaket ist deshalb ausdrücklich ein Entwicklungspilot.

Vor Beginn einer Aufnahme wird der FIFO neu gestartet. Nicht aufgezeichnete Vorlaufwerte werden an dieser Grenze bewusst verworfen. Die Rohdatei enthält X, Y und Z in g, Sampleindex, Host-Zeitstempel, relative Zeit, eine aus Sampleindex/200 berechnete Sensorzeitschätzung, FIFO-Füllstand, Lesezeit und Qualitätsflags. Hinzu kommen Label und Aufnahmezurordnung. Ein XYZ-Messpunkt enthält drei einzelne Achsenwerte. Die Punktzahl wird nicht durch die Zahl der Achsen geteilt, wenn bereits vollständige CSV-Zeilen gezählt werden.

Die beobachtete Rate wird als $(N - 1)/(t_N - t_1)$ aus den Host-Zeitstempeln bestimmt. Sie liegt in den v4-Läufen ungefähr bei 207 XYZ/s. Die Sensorzeitschätzung aus Sampleindex/200 bleibt davon getrennt: Sie ist eine Rechnung mit dem Nominalwert und keine zweite unabhängige Uhr. Host-Leseabstände dürfen schwanken, weil der Sensor puffert und die Software den FIFO ausliest. Ein auffälliger Leseabstand beweist daher allein weder eine fehlerhafte Sensorausgaberate noch einen Verlust.

Ein gesetztes Gap-, Overrun- oder Sättigungsflag kennzeichnet betroffene Daten. Zusätzlich werden nicht endliche Zahlen, ein voller FIFO und Host-Abstände über 160 ms geprüft. Die 160 ms entsprechen der nominellen Zeitkapazität von 32 FIFO-Punkten bei 200 Hz. Ein als kritisch erkennbarer Abschnitt bleibt gespeichert und wird bei der Modellbewertung ungültig. Ein Nullbefund aller Flags bedeutet, dass die implementierten Kriterien keinen Fehler anzeigen. Die genaue Anzahl möglicherweise verlorener physikalischer Sensorwerte bleibt unbekannt.

6.4 Gemeinsame Fensterbildung und Vorverarbeitung

Die Rohaufnahmen werden vor der Fensterbildung vollständig Training, Validierung oder Test zugeordnet. Es erfolgt keine zufällige Verteilung benachbarter Fenster auf verschiedene Teilmengen. Für das v4-Pilotpaket ist der Abschnitt [180,300) Sekunden seit Aufruf des PWM-Stellbefehls festgelegt. Die ersten 180 Sekunden bleiben als Rohdaten erhalten. Die Abschnittswahl ist ein vorläufiger Einlaufkandidat und kein bereits bewiesener Zeitpunkt stationären Verhaltens.

Ab dem ersten XYZ-Punkt innerhalb dieses Abschnitts werden Gruppen mit $H = 128$ Punkten und Schrittweite $S = 128$ gebildet. Die Fenster überlappen nicht und überschreiten keine Aufnahmegrenzen. Eine unvollständige Restgruppe wird separat gezählt und weder aufgefüllt noch mit einer Folgeaufnahme verbunden. Bei ungefähr 207 XYZ/s enthält der 120-s-Abschnitt typischerweise 194 vollständige Modellfenster. Die nominelle Fensterdauer beträgt 0,64 s; das aus dem beobachteten Durchsatz abgeleitete Intervall liegt ungefähr bei 0,618 s.

Für jede Achse wird zunächst der Mittelwert des jeweiligen 128er-Rohfensters in Float64 berechnet und abgezogen. Erst danach wird das Ergebnis in Float32 überführt. Der gespeicherte, ausschließlich auf den Trainingsdaten angepasste Scaler wird anschließend unverändert angewendet. Die genaue Reihenfolge ist Teil des Paketvertrags. Ein zuvor nach Float32 gerundeter Rohdatenexport darf nicht als Ersatz für die ursprünglichen Float64-

Werte erneut zentriert werden. Auch die Reduktionsreihenfolge der achsenweisen Mittelwertbildung wird im Import- und Liveweg beibehalten.

Die gemeinsame Standardisierung verwendet die gespeicherten Skalen $s_X = 0,00940231$ g, $s_Y = 0,01110453$ g und $s_Z = 0,02685052$ g. Die zusätzlich gespeicherten Trainingsmittelwerte liegen nahe null und werden dennoch angewendet. Für die Analyse gilt schematisch $z_{ij} = (a_{ij} - \mu_j)/s_j$, wobei a_{ij} bereits den achsenweise zentrierten Beschleunigungswert bezeichnet. Scaler, Modelle und Schwellen werden im Testweg niemals neu angepasst.

Die drei Methoden erhalten dieselben standardisierten 128×3 -Werte. Der gemeinsame Offline-Vergleich verwendet Kopien desselben Eingabefensters, sodass ein veränderlicher Arbeitsbuffer eines Verfahrens die nächste Methode nicht beeinflusst. Ungültige Eingaben erzeugen keine normale Entscheidung. Die Prüfung der Rechengenauigkeit verbindet vorbereitete Trainingsdaten, den Import neuer Aufnahmen, Offline-Replay und den Liveadapter.

6.5 Modellpaket, Training und Kalibrierung

Das eingefrorene Paket run_001 enthält die Modellartefakte, den Scaler, die Schwellen, den Vorverarbeitungsvertrag, ein Manifest der Ursprungsaufnahmen und die zugehörigen SHA-256-Prüfsummen. Das Training verwendete zwei vollständige normale 300-s-Aufnahmen; eine dritte normale Aufnahme diente der Validierung und Schwellenkalibrierung. Nach der festgelegten Abschnittsauswahl ergeben sich 388 Trainings- und 194 Validierungsfenster. Der Scaler wurde auf 49.664 XYZ-Punkten aus den kanonischen Trainingsfenstern angepasst. Keine unabhängige Testaufnahme war daran beteiligt.

Die neuronale Architektur ist ein kleiner eindimensionaler Faltungsautoencoder. Der Encoder verarbeitet die drei Achsen mit zwei Conv1D-Schichten und zwei Poolingstufen. Der Decoder rekonstruiert die zeitliche Auflösung durch Upsampling und weitere Faltungen. Alle Faltungen außer der linearen Ausgangsschicht verwenden ReLU. Das Modell hat 507 trainierbare Parameter. Diese geringe Größe ist eine bewusste Pilotentscheidung und kein Beleg für eine optimale Architektur oder ausreichende Fehlerempfindlichkeit.

Tabelle 6-3: Architektur des ausgeführten Autoencoders

Stufe	Operation	Ausgabeform ohne Batchdimension
Eingabe	Standardisierte XYZ-Werte	128×3
Encoder 1	Conv1D, 8 Filter, Kernel 5; MaxPooling 2	64×8
Encoder 2	Conv1D, 4 Filter, Kernel 3; MaxPooling 2	32×4
Decoder 1	Conv1D, 4 Filter, Kernel 3; Upsampling 2	64×4
Decoder 2	Conv1D, 8 Filter, Kernel 3; Upsampling 2	128×8
Rekonstruktion	Conv1D, 3 Filter, Kernel 5; linear	128×3

Das protokollierte Training lief mit Batchgröße 32 und festgelegten Zufallsinitialisierungen 42 über 100 Epochen. Die beste gespeicherte Epoche war zugleich die letzte. Eine vorgesehene Early-Stopping-Patience von zehn Epochen beendete diesen Lauf nicht vorzeitig. Der letzte Trainingsverlust betrug rund 0,37920, der Validierungsverlust rund 0,42963. Diese Werte beschreiben die Optimierung auf Entwicklungsdaten. Sie belegen weder Konvergenz noch eine spätere Erkennungsleistung. Weitere Architekturversuche oder ein Nachtraining anhand der Testergebnisse wurden nicht durchgeführt.

Tabelle 6-4: Scores und eingefrorene Entscheidungsschwellen

Methode	Berechnung bzw. Modell	Schwelle
RMS	Quadratwurzel des Mittelwerts aller 384 quadrierten standardisierten Werte	1,2747695377
Isolation Forest	200 Bäume; 384 Werte in fester Reihenfolge; negatives score_samples	0,5045395247
TFLite-Autoencoder	Mittlerer quadratischer Rekonstruktionsfehler über alle 128×3 Werte	0,5443579661

Die RMS-Baseline ist dimensionslos. Sie ist nicht mit dem physikalischen Vektor-AC-RMS in g gleichzusetzen. Der Isolation Forest verwendet die Fensterwerte als einen 384-dimensionalen Vektor; er besitzt keine explizite zeitliche Nachbarschaftsstruktur. Seine Parameter umfassen 200 Bäume, max_samples = auto, einen Ausführungsthread und den Zufallsstartwert 42. Die Richtung des Scores wird so vereinheitlicht, dass größere Werte für alle drei Verfahren stärkere Auffälligkeit bedeuten.

Alle Schwellen folgen dem empirischen 99. Perzentil normaler Validierungsscores mit der dokumentierten linearen Quantilsinterpolation. Ein Fenster wird nur bei Score > Schwelle als auffällig bewertet. Gleichheit genügt nicht. Auf 194 Kalibrierungsfenstern lagen bei jeder Methode zwei Scores oberhalb der eigenen Schwelle. Dieser aus der Kalibrierung resultierende Anteil von rund 1,03 % ist keine unabhängige Fehlalarmmessung und garantiert keine spätere Fehlalarmrate von 1 %.

Der Autoencoder wurde ohne Quantisierung in ein Float32-TFLite-Modell konvertiert. Die Prüfung gegen die Keras-Ausführung umfasste die 194 normalen Validierungsfenster. Die maximale absolute Rekonstruktionsabweichung lag bei rund $1,79 \cdot 10^{-6}$, die maximale Abweichung des mittleren quadratischen Fehlers bei rund $6,15 \cdot 10^{-8}$. Es trat kein Entscheidungsunterschied auf. Die ursprüngliche Autoencoder-Schwelle blieb erhalten; die Konvertierung führte zu keiner erneuten Kalibrierung. Der geprüfte Interpreter auf dem Pi ist ai-edge-litert 2.1.6. Das Paket behält den Status ready_development_only, weil technische Kompatibilität die offenen physikalischen Nachweise nicht ersetzt.

6.6 Lokaler Datenweg und Ressourceninstrumentierung

Die Software trennt Sensorzugriff, Fensterbildung, Modellauswertung, Stellsteuerung und Berichtserzeugung. Für die unabhängigen Tests wird das eingefrorene Paket ausschließlich geladen. Neue Aufnahme-IDs, Dateipfade und Hashes werden gegen bereits für Training, Validierung und Parameterwahl verwendete Daten geprüft. Fehlerhafte Provenienz oder eine veränderte Paketkennung führen zur Zurückweisung der Aufnahme. Historische Daten und Berichte bleiben erhalten.

Tabelle 6-5: Komponenten des geprüften Datenwegs

Aufgabe	Zentrale Module	Funktion
Erfassung	adxl345.py; collect_real_data.py; pilot_sensor_source.py	Sensor konfigurieren, FIFO auslesen, Rohdaten und Qualität speichern
Aktuator	fan_pwm.py; Messablaufprogramme	Hardware-PWM prüfen, setzen und ausdrücklich auf 0 % zurückstellen
Datenaufbereitung	prepare_pilot_dataset.py	Aufnahmeweise Zuordnung und kanonische Float64/Float32-Fenster
Gemeinsamer Vergleich	pilot_method_comparison.py; common_comparison.py	Gespeicherte Skalierung, drei Scores und feste Schwellen
Unabhängiger Import	independent_normal_test.py; controlled_airflow_test.py; second_pwm_normal_test.py	Herkunft, Zeitabschnitt, Zustandslabel und Datenqualität prüfen
Lokale Ausführung	pilot_stream_final.py; pilot_runtime_final.py; pilot_recorder_final.py	Begrenzte Queue, unveränderter Modellweg und getrennte Zeitmessung
Laufzeitversuch	run_final_runtime_evidence.py	Ein protokollierter Prozess je Methode und Lauf; kein Wiederholungsstart nach Fehler

Im Sensor-Livebetrieb liest ein Erfassungsthread die XYZ-Punkte, schreibt die Rohdaten und bildet die vollständigen Fenster. Eine auf vier Fenster begrenzte Queue übergibt sie an die Modellauswertung. Bei voller Queue wird das neu eintreffende Entscheidungsfenster als verworfen protokolliert. Die Rohdaten bleiben erhalten. Die Bilanz unterscheidet gebildete, ausgegebene, verworfene und beim Abbruch unverarbeitete Fenster. Ungültige Entscheidungen werden nicht als normal gezählt.

Die Instrumentierung trennt Fensteraufbau einschließlich Mittelwertentfernung, Wartezeit in der Queue, Standardisierung, Verfahrensaufruf und verfügbare Entscheidung. Beim Autoencoder werden Eingabeübertragung, Interpreter.invoke, Ausgabeübertragung und anschließende Fehlerberechnung getrennt erfasst. Für Isolation Forest bezeichnet der Rechenkern den Aufruf score_samples, für RMS die Kennwertberechnung. Die gesamte Verarbeitungslatenz endet mit der verfügbaren Entscheidung, bevor diese ins Entscheidungsjournal geschrieben wird. Fensterfüllzeit und die vor dem Host-Zeitstempel liegende Sensorauslesezeit gehören nicht zu dieser Latenz.

Ein Monitor schreibt Prozess-CPU, Resident Set Size (RSS), Prozessspitzenwert und Queue-Füllstand im Abstand von ungefähr 100 ms in eine separate Datei. 100 % CPU entsprechen der Auslastung eines logischen Kerns. Der Speicher umfasst auch Python, Bibliotheken,

Erfassung und Protokollierung. Die kleinen Modelldateien sind daher nicht mit dem Prozessspeicher gleichzusetzen. Kaltstart, Laden und zwanzig vorbereitende Modellaufrufe werden außerhalb des eigentlichen Messabschnitts dokumentiert.

Der Ressourcenvergleich verwendet je Methode einen eigenen Prozess. Im Sensorbetrieb werden neue Normaldaten aufgenommen; im Offline-Replay wird dieselbe gespeicherte Aufnahme mit ihren ursprünglichen Host-Abständen wiedergegeben. Die Wiedergabe hält die Eingabedaten vorab im Speicher. Ihre RSS-Werte sind deshalb nicht unmittelbar als Speicherbedarf der Sensorerfassung zu interpretieren. Die beiden Betriebsarten erhalten getrennte Ergebnistabellen. Eine grafische Oberfläche ist im nachgewiesenen Kern nicht enthalten. Der vorhandene frühere GUI-Prototyp ist damit keine validierte Bedienoberfläche des neuen Pakets.

6.7 Festgelegte Versuche und Nachweisgrenzen

Die unabhängigen Normaltests umfassen drei separate Starts bei 75 % PWM. Der kontrolliert veränderte Testzustand wird in einer vollständigen Folge Normal → Platte → Normal bei gleicher PWM untersucht. Ein weiterer Versuch verwendet drei normale Starts bei 50 % PWM mit unverändertem Paket. Die Modelle bewerten durchgehend dieselbe Art von 128er-Fenstern im zuvor festgelegten Abschnitt [180,300). Hohe Fehlalarmraten werden als Ergebnisse erhalten. Die Abschnittsauswahl, Skalierung und Schwellen werden nach Sichtung der Testdaten nicht geändert.

Ergänzend werden die Beschleunigungen in gleich langen 5-s-Abschnitten diagnostisch ausgewertet. Innerhalb jedes Abschnitts wird der jeweilige Achsenmittelwert entfernt. Der physikalische Vektor-AC-RMS lautet $R_{AC} = \sqrt{[\text{mean}((X - \bar{X})^2 + (Y - \bar{Y})^2 + (Z - \bar{Z})^2)]}$. Er wird in g beziehungsweise mg angegeben; 1 mg entspricht 0,001 g. Er besitzt weder dieselbe Fensterlänge noch dieselbe Skalierung wie die drei Modellscores. Diese Trennung gilt auch für die explorative Fehleranalyse.

Die Softwareprüfung des abschließenden Livewegs umfasst 18 gezielte Tests. Sie prüft die Übereinstimmung der Scores auf realen eingefrorenen Referenzfenstern sowie Fehlerpfade für Datenqualität, Überlast und geordnetes Beenden. Die zusätzlichen Hardwareläufe liefern den Nachweis der tatsächlichen lokalen Verarbeitung. Eine nachgewiesene Defektklasse, eine unabhängige Drehzahlmessung und eine vollständig kalibrierte physikalische Zeitbasis gehören weiterhin zu den offenen Nachweisen. Kapitel 7 bewertet die Anforderungen deshalb einzeln und setzt eine erfolgreiche Programmausführung nicht mit der vollständigen Erfüllung aller MUSS-Anforderungen gleich.

7 Evaluation und Ergebnisse

Die Evaluation betrachtet Erfassung, numerische Konsistenz, Fehlalarme, Reaktion auf den Plattenzustand und technischen Aufwand getrennt. Alle hier verglichenen Erkennungsergebnisse verwenden das eingefrorene v4-Paket mit unveränderten Modellen, Skalierungen, Schwellen und Testabschnitten. Die Dateiverweise im Anhang führen zu Rohdaten, Metadaten, vorab festgelegten Protokollen und maschinenlesbaren Ergebnissen. Nachträgliche Ursachenuntersuchungen sind als explorative Fehleranalyse gekennzeichnet.

7.1 Datenbasis und Auswertungseinheit

Tabelle 7-1: Aufnahmen für Entwicklung und unabhängige Erkennungsprüfung

Gruppe	Vollständige Aufnahmen	Verwendung	Vollständige 128er-Fenster
Normales Training, 75 %	2 × 300 s	Modell- und Scaleranpassung	388
Normale Validierung, 75 %	1 × 300 s	Entwicklungsprüfung und Schwellen	194
Erste unabhängige Normaltests, 75 %	3 × 300 s	Fehlalarmprüfung	582
Zusätzliche Normalreferenz vom 11.09., 75 %	1 × 300 s	Eigenständiger Test; anschließender Plattenstart abgebrochen	194
Folge vom 12.09.: Normal → Platte → Normal, 75 %	3 × 300 s	Zwei Normalreferenzen und ein veränderter Zustand	582
Zweiter Normalbetriebspunkt, 50 %	3 × 300 s	Unverändertes Paket unter geänderter Normalbedingung	582

Die ersten beiden Normalaufnahmen der Entwicklungsfolge und der zusätzliche normale Entwicklungsstart wurden später für Training beziehungsweise Validierung verwendet. Sie werden im Testvergleich nicht nochmals als unabhängige Bestätigung gezählt. Die früheren Aufbauversionen bleiben ausgeschlossen. Der zusätzliche Normaltest vom 11. September bleibt erhalten, obwohl der damals geplante anschließende Plattenlauf vor einer Aufnahme an einer nicht passenden Pin-Funktion scheiterte. Es wurde kein fehlender Lauf als erfolgreich protokolliert und keine Datei durch einen Ersatz überschrieben.

In der unabhängigen Erkennungsprüfung liegen damit neun normale Aufnahmen und eine Aufnahme des kontrolliert veränderten Zustands vor. Jede ergibt 194 gültige Fenster im festgelegten Abschnitt; ungültige Bewertungsfenster wurden in diesen Abschnitten nicht festgestellt. Das ergibt 1.746 normale und 194 veränderte Fenster. Die Fenster dienen der zeitlichen Auflösung und zählen nicht als ebenso viele unabhängige Versuchsreplikate. Insbesondere ist eine einzelne Plattenfolge keine statistisch belastbare Reproduzierbarkeitsprüfung.

Die zusätzlich aufgenommenen Laufzeitversuche werden gesondert behandelt. Sie dienen der Prüfung des lokalen Datenwegs und des technischen Aufwands. Die vorab ausgewählte Datenbasis für den Vergleich der Fehlalarmraten wird durch diese späteren Versuche nicht nachträglich erweitert oder neu gewichtet.

7.2 Erfassungsqualität und physikalische Zeitbasis

Die v4-Aufnahmen enthalten vollständige XYZ-Punkte mit steigenden monotonen Host-Zeitstempeln und fortlaufenden Softwareindices. Die drei neuen 50%-Normalaufnahmen enthalten 62.142, 62.133 und 62.133 XYZ-Punkte. Ihre beobachteten Raten betragen 207,1442, 207,1118 und 207,1145 XYZ/s. Der erste Punkt liegt jeweils rund 95–98 ms nach dem Aufruf des Stellbefehls. Die längsten Host-Leseabstände betragen 8,576, 9,790 und 9,427 ms. Gap-, Overrun- und Sättigungsflags sind in allen drei Rohaufnahmen null; nicht endliche Werte oder nicht monotone Zeitstempel wurden nicht gefunden.

Die abgeschlossene Plattenfolge zeigt ebenfalls einen Durchsatz von ungefähr 207 XYZ/s. Die Messdauer wird durch Host-Zeitstempel begrenzt, nicht durch eine fest angeforderte Zahl von 60.000 Punkten. Die rund 62.100 Punkte je 300 s sind daher keine versehentliche Addition der Achsenwerte. Entsprechend waren die früher diskutierten 6.205 Werte einer 30-s-Datei vollständige XYZ-Zeilen und somit 18.615 einzelne Achsenwerte. Die Abweichung von nominell 200 Hz ist wiederholt beobachtet und nicht durch eine Bezeichnungskorrektur beseitigt.

Gesichert sind die programmierte ODR, die zurückgelesenen Register, der FIFO-Erfassungsweg und der mittlere Durchsatz nach der Host-Uhr. Nicht gesichert ist die Ursache der ungefähr 3,5 % höheren Rate. Die vorhandenen Aufnahmen enthalten keine unabhängig gemessenen Wandlungszeitpunkte oder ein externes Referenzsignal. Eine Abweichung des realen Sensortakts ist eine mögliche Erklärung; ohne direkten Nachweis wird sie nicht zur festgestellten Ursache erklärt. Ein vollständiger Ausschluss unerkannter Verluste, von Aliasing oder von Problemen der physikalischen Bandbegrenzung ist ebenfalls nicht möglich.

Die bereits vor dem Modelltraining ausgeführte Spektralprüfung der v4-Entwicklungsdaten fand einen gemeinsamen dominanten Anteil bei ungefähr 39,45 Hz auf der aus dem Durchsatz geschätzten 1024er-FFT-Achse. Auf einer mit 200 Hz beschrifteten Achse liegt derselbe Bin bei 38,08594 Hz. Unterschiede dieser Zahlen entstehen durch die Achsenskalierung und sind kein Drehzahlnachweis. Auch die gröbere 128er-Diagnostik besitzt ein anderes Frequenzraster. Der Signalabstand zum Stillstand und eine starke gemeinsame Spektrallinie belegen messbare Betriebsanregung, aber keine Empfindlichkeit für einen bestimmten Defekt.

7.3 Fehlalarme bei unverändertem Normalbetrieb

Tabelle 7-2: Unabhängige Normalaufnahmen bei 75 % PWM

Aufnahme	gültig / ungültig	RMS: Fehlalarme	Isolation Forest: Fehlalarme	Autoencoder: Fehlalarme
Normaltest 1, 11.09.	194 / 0	57 (29,38 %)	34 (17,53 %)	0 (0,00 %)
Normaltest 2, 11.09.	194 / 0	0 (0,00 %)	0 (0,00 %)	0 (0,00 %)
Normaltest 3, 11.09.	194 / 0	0 (0,00 %)	0 (0,00 %)	0 (0,00 %)
Zusätzliche Normalreferenz, 11.09.	194 / 0	2 (1,03 %)	1 (0,52 %)	9 (4,64 %)
normal_before, 12.09.	194 / 0	1 (0,52 %)	0 (0,00 %)	51 (26,29 %)
normal_after, 12.09.	194 / 0	0 (0,00 %)	0 (0,00 %)	4 (2,06 %)
Zusammengefasst	1.164 / 0	60 (5,15 %)	35 (3,01 %)	64 (5,50 %)

Die Methoden reagieren nicht gleich auf die Variation zwischen normalen Starts. Der erste unabhängige Normaltest erzeugt vor allem RMS- und Isolation-Forest-Fehlalarme. Dagegen fällt der Autoencoder in der späteren Aufnahme normal_before durch 51 Fehlalarme auf. Die Zusammenfassung verschleiert diese Unterschiede teilweise. Kein Verfahren zeigt auf allen normalen Aufnahmen den bei der Validierung beobachteten Alarmanteil von ungefähr 1 %.

Die Fehlalarmrate wird ausschließlich unter gültigen normalen Fenstern berechnet. Sie ist eine Beschreibung dieser Testaufnahmen und keine Schätzung mit 1.164 unabhängigen Wiederholungen. Zeitlich benachbarte Fenster sind abhängig. Die einzelnen Starts unter derselben Montage decken außerdem nur einen kleinen Ausschnitt möglicher Normalbedingungen ab.

7.4 Kontrollierte Luftstromveränderung und Rückkehrreferenz

Die am 12. September abgeschlossene Folge verwendet die Labels normal_before, airflow_modified und normal_after. Alle drei Aufnahmen dauerten 300 s bei 75 % PWM und 25 kHz. Die Platte blieb während ihres Laufs unverändert positioniert. Vor ihrem Einsetzen und Entfernen erfolgten die manuell freigegebenen Umbaupausen. Einheitliche zusätzliche Wartezeiten von 60 s bedeuten dabei keine identischen gesamten Auszeiten.

Tabelle 7-3: Entscheidungen der drei Methoden in der vollständigen Plattenfolge

Zustand	gültige Fenster	RMS: auffällig	Isolation Forest: auffällig	Autoencoder: auffällig
Normal vorher	194	1 (0,52 %)	0 (0,00 %)	51 (26,29 %)
Luftstrom verändert	194	7 (3,61 %)	4 (2,06 %)	0 (0,00 %)
Normal nachher	194	0 (0,00 %)	0 (0,00 %)	4 (2,06 %)

Bei den Normalreferenzen sind die auffälligen Entscheidungen Fehlalarme. Für die Plattenaufnahme wird der Alarmanteil unter einem kontrolliert veränderten Betriebszustand angegeben. Er ist kein allgemeiner Defekt-Recall. Der Autoencoder markiert keinen ihrer 194 Fenster als auffällig, obwohl die physikalische Vibrationsstärke gegenüber beiden

benachbarten Normalreferenzen steigt. RMS und Isolation Forest reagieren nur auf wenige Fenster. Eine zuverlässige Unterscheidung dieses veränderten Zustands ist mit dem Paket damit nicht belegt.




Abbildung 7-1: Eingefrorene Scores auf identischen 128er-Fenstern der unabhängigen Folge. Die gestrichelten Linien sind die vorab fixierten Schwellen. Diese Verläufe sind von den 5-s-RMS-Werten zu unterscheiden. Quelle: eigene unveränderte Testauswertung.

Die Streuung in der folgenden Tabelle ist die Standardabweichung der 24 Abschnittswerte mit dem Nenner $n - 1$. Sie beschreibt die beobachtete Variation innerhalb einer Aufnahme und ist kein Standardfehler aus 24 unabhängigen Versuchen.

Tabelle 7-4: Physikalischer Vektor-AC-RMS der 5-s-Abschnitte von 180 bis 300 s

Zustand	Mittelwert [mg]	Streuung der 24 Abschnitte [mg]	beobachteter Bereich [mg]	lineare Steigung [mg/min]
Normal vorher	28,458	1,618	26,593–33,214	–0,707
Luftstrom verändert	38,053	1,299	36,386–41,676	–0,903
Normal nachher	32,074	2,781	26,866–35,349	–0,544

Die 5-s-Zeitabschnitte sind am Stellbefehl ausgerichtet. Im ersten Abschnitt fehlen jeweils die dokumentierten rund 0,1 s bis zum ersten XYZ-Punkt; der RMS wird aus den vorhandenen Punkten berechnet. Diese Anfangslücke wird nicht durch erfundene oder interpolierte Werte aufgefüllt. Die Zahl der Punkte je Zeitabschnitt muss deshalb nicht identisch sein.




Abbildung 7-2: Vollständige 5-s-RMS-Verläufe der unabhängigen Folge Normal → Platte → Normal. Die Markierung bei 180 s kennzeichnet den vorab gewählten Prüfabschnitt. Quelle: eigene Messungen vom 12.09.2026.

Nach Entfernen der Platte sinkt das mittlere Vibrationsniveau, kehrt aber nicht vollständig zum vorherigen Mittelwert zurück. Die Differenz zwischen beiden Normalreferenzen beträgt 3,616 mg beziehungsweise 12,71 % des vorherigen Mittels. Dreizehn der 24 nachherigen 5-s-Werte liegen im zuvor beobachteten Bereich. Diese Bereichsüberlappung beweist keine Gleichwertigkeit; die Abweichung ist aber ebenso wenig ein Beleg für einen entstandenen Defekt. Der Unterschied Platte–Nachher beträgt 5,978 mg und ist kleiner als die gesamte beobachtete Spannweite beider Normalreferenzen von 8,756 mg.

Die linearen Steigungen in Tabelle 7-4 beschreiben Verläufe innerhalb einzelner Aufnahmen. Sie werden nicht mit den unterschiedlichen Mittelwerten zwischen Starts verwechselt. Beispielsweise unterscheiden sich die Mittelwerte der ersten und zweiten Hälfte von

normal_before nur um rund +0,046 mg, obwohl die lineare Anpassung eine negative Steigung ergibt. Schwankungen und einzelne Abschnitte beeinflussen die Anpassung. Aus diesen Daten ergibt sich kein Nachweis eines über alle Starts gleichen kontinuierlichen Einlauffrends. Die 180 Sekunden bleiben deshalb ein unveränderter Prüfkandidat, nicht eine nachträglich verschobene Grenze und nicht eine allgemeine Stationaritätsgarantie.

7.5 Explorative Fehleranalyse der Modellentscheidungen

Die Frage, weshalb der Autoencoder im Normalzustand 51 von 194 Fenstern markiert, im Plattenzustand aber kein einziges, wurde nach Kenntnis der Testergebnisse untersucht. Diese Untersuchung ist ausdrücklich eine explorative Fehleranalyse. Sie ändert weder die Schwelle noch die Auswahl des Testabschnitts und liefert keinen zusätzlichen unabhängigen Test. Für jeden Vergleich wurden exakt dieselben 128er-Fenster des eingefrorenen Datenwegs verwendet. Die in Abbildung 7-2 dargestellten 5-s-Kennwerte wurden nicht als Modellscores eingesetzt.

Die Signalstärke in physikalischen Einheiten erklärt die Entscheidungen nicht allein. Der Mittelwert des physischen Vektor-AC-RMS der Modellfenster steigt von rund 28,408 mg vor der Änderung auf 38,025 mg mit Platte. Rund 95 % des Zuwachses der mittleren quadratischen Signalenergie entfallen auf die Z-Achse. Die Standardisierung gewichtet diese Achse jedoch schwächer. Bezogen auf dieselbe physische quadratische Amplitude beträgt das Gewicht der X-Achse ungefähr das 8,16-Fache und das der Y-Achse das 5,85-Fache des Gewichts der Z-Achse. Diese Verhältnisse folgen unmittelbar aus den inversen Quadraten der gespeicherten Skalierungsfaktoren.

Tabelle 7-5: Mittlerer Autoencoder-Rekonstruktionsfehler je Achse auf identischen Modellfenstern

Zustand	MSE X	MSE Y	MSE Z	gesamter MSE
Normal vorher	0,824745	0,538481	0,175125	0,5128
Luftstrom verändert	0,621914	0,473663	0,184719	0,4268

Der Gesamtfehler ist das arithmetische Mittel der drei Achsenfehler. Der mit Platte geringfügig höhere Z-Fehler wird durch kleinere X- und Y-Fehler überkompensiert. Die gespeicherte obere Schwelle von rund 0,54436 wird deshalb seltener und in dieser Aufnahme überhaupt nicht überschritten. Ein größerer physischer Vektor-RMS muss bei dieser Vorverarbeitung und diesem Modell somit keinen größeren Anomaliescore verursachen. Auch der RMS-Modellscore wird aus standardisierten Werten berechnet und ist nicht identisch mit dem physischen Vektor-AC-RMS.




Abbildung 7-3: Achsenbeiträge zur physischen Energie, zur standardisierten Energie und zum Autoencoder-Fehler auf denselben 128er-Fenstern. Dargestellt sind Mittelwerte je Aufnahme; sie ersetzen nicht die Entscheidungen einzelner Fenster. Quelle: eigene explorative Auswertung.

Vierzig der 51 Autoencoder-Fehlalarme in `normal_before` liegen in den ersten 60 s des ausgewerteten Abschnitts, also zwischen 180 und 240 s ab dem Stellbefehl. Innerhalb dieser Aufnahme besteht ein starker positiver Zusammenhang des Fehlers mit der X-Schwingungsstärke; die explorativ berechnete Korrelation beträgt ungefähr 0,82. Mit der Z-Schwingungsstärke besteht kein vergleichbar ausgeprägter Zusammenhang. Die Fehlalarme kennzeichnen daher keine einfache Überschreitung der Gesamtvibration.

Die Spektralanalyse zeigt keine ausschließlich in den fehlerhaft markierten Fenstern vorkommende neue dominante Linie. Ein gemeinsamer dominanter Z-Anteil liegt im groben 128er-Raster bei Bin 24: 37,5 Hz bei nominell 200 Hz beziehungsweise ungefähr 38,8 Hz bei Skalierung mit dem beobachteten Durchsatz. Das ist mit dem gemeinsamen Schwingungsanteil der höher aufgelösten Entwicklungsanalyse vereinbar. Die Frequenzraster

sind verschieden; aus den Binmitten wird keine unterschiedliche tatsächliche Drehzahl abgeleitet.

Der Plattenzustand liegt in den untersuchten Einzelmerkmalen weitgehend innerhalb bereits bekannter normaler Variation. Beim physischen Modellfenster-RMS liegen 188 von 194 Plattenfenstern innerhalb der Spannweite der normalen Validierungsaufnahme; unter Einbezug der zuvor untersuchten Normalaufnahmen sind es 194. Auch alle 194 Autoencoder-Scores liegen innerhalb der Spannweite der Normalvalidierung. Ein Vergleich eindimensionaler Spannweiten beweist keine Gleichheit der gemeinsamen Verteilungen. Er erklärt jedoch, weshalb diese Merkmale keine klare neue Abweichung anzeigen müssen. Die Prüfkette selbst wurde anhand identischer Fenster und Scores abgeglichen; die beobachtete geringe Trennung wird nicht als Import- oder Rundungsfehler umgedeutet.

Belegt sind die Achsengewichtung, die kleineren X- und Y-Rekonstruktionsfehler, die zeitliche Häufung der normalen Fehlalarme und die genannten Merkmalsüberlappungen. Ungeklärt bleibt, welche physikalischen Mechanismen die Unterschiede zwischen den Starts erzeugen. Kontaktbedingungen, Aufstellungsdynamik, thermische Einflüsse, Luftströmung und Drehzahländerungen sind mögliche Ursachen. Ohne gezielte Messung sind sie keine festgestellten Erklärungen.

7.6 Zweiter normaler Betriebspunkt bei 50 % PWM

Für FF4 wurden drei zusätzliche Normalstarts ohne Platte bei 50 % PWM und unverändertem Aufbau v4 aufgezeichnet. Modelle, Skalierung, Schwellen, Sensorregister und Bewertungsabschnitt blieben gleich. Die niedrigere Stellvorgabe wurde vorab als zweite normale Bedingung festgelegt. Ihre Daten wurden weder zum Nachtraining noch zur erneuten Kalibrierung verwendet. Ein Tastgradwechsel ist nicht gleichbedeutend mit einer gemessenen Drehzahländerung.

Tabelle 7-6: Fehlalarme im zweiten normalen Betriebspunkt

Aufnahme	gültig / ungültig	RMS	Isolation Forest	Autoencoder
50 %, Lauf 1	194 / 0	1 (0,52 %)	0 (0,00 %)	17 (8,76 %)
50 %, Lauf 2	194 / 0	2 (1,03 %)	1 (0,52 %)	11 (5,67 %)
50 %, Lauf 3	194 / 0	0 (0,00 %)	0 (0,00 %)	7 (3,61 %)
50 %, zusammen	582 / 0	3 (0,52 %)	1 (0,17 %)	35 (6,01 %)
75 %, sechs frühere Normalaufnahmen	1.164 / 0	60 (5,15 %)	35 (3,01 %)	64 (5,50 %)




Abbildung 7-4: Fehlalarmraten je vollständiger Normalaufnahme und zusammengefasst bei 75 % und 50 % PWM mit demselben eingefrorenen Paket. Die Aufnahmen sind nicht zeitgleich oder randomisiert gepaart. Quelle: eigene Testauswertung.

Bei RMS und Isolation Forest sinkt der zusammengefasste Fehlalarmanteil im vorliegenden Vergleich. Beim Autoencoder steigt er von 5,50 % auf 6,01 %, also um ungefähr 0,52 Prozentpunkte. Innerhalb der drei 50-%-Starts nimmt sein Anteil von 8,76 % auf 3,61 % ab. Das erlaubt keine allgemeine Aussage, eine niedrigere PWM sei günstiger oder ungünstiger. Die Methoden reagieren unterschiedlich, und die zeitlich getrennten Reihen isolieren die PWM nicht von sämtlichen weiteren Einflüssen. H3 wird deshalb nicht als allgemeine oder kausal nachgewiesene Zunahme bestätigt.

Die physischen 5-s-RMS-Mittelwerte im späten Abschnitt liegen bei 16,761, 16,600 und 16,485 mg. Die Streuungen innerhalb der Läufe betragen 0,690, 1,226 und 0,308 mg. Im zweiten Lauf reicht die Spannweite bis 21,918 mg, obwohl sein Mittelwert nahe an denen der anderen Starts liegt. Ein ähnlicher Mittelwert bedeutet folglich keine identischen Verläufe. Die niedrigere physische Amplitude allein begründet keine Änderung des primären 75-%-Modellpakets.

7.7 Laufzeit, Ressourcen und lokaler Sensorbetrieb

Für jede Methode wurden drei neue Prozesse im Sensor-Livebetrieb und drei getrennte Prozesse mit zeitgetreuem Offline-Replay ausgeführt. Die Reihenfolge der Methoden wurde zwischen den Wiederholungen rotiert. Jeder Prozess erfasst beziehungsweise spielt 300 s ab; die Modellverarbeitung bewertet ausschließlich den festgelegten Abschnitt [180,300) s. Daraus folgen je Prozess 120 s aktive Bewertungszeit. Zwanzig synthetische Aufwärmufrufe erfolgten vor dem Messbeginn. Sie verändern keine Parameter.

Jeder Sensorstart verwendet 75 % PWM und 25 kHz nach mindestens 60 s zusätzlicher softwareseitiger Auszeit. Ein Prozess enthält jeweils nur eine der drei Methoden. Alle neun Replay-Prozesse verwenden dieselbe vorhandene normale Rohaufnahme mit ihren

ursprünglichen Host-Leseabständen. Diese Wiederholungen messen Softwareverhalten; sie sind keine zusätzlichen unabhängigen physikalischen Versuche.

Tabelle 7-7: Latenz je Methode und Betriebsart; Bereich der drei getrennten Prozesse

Betriebsart / Methode	P99 gesamt [ms]	P99 Rechenkern [ms]	größtes Maximum gesamt [ms]	Überschreitungen
Sensor / RMS	6,113–6,203	0,045–0,049	7,908	0
Sensor / Isolation Forest	27,896–28,577	22,004–22,049	29,234	0
Sensor / TFLite-Autoencoder	6,261–7,062	0,086–0,114	8,207	0
Replay / RMS	6,077–6,558	0,045–0,057	7,519	0
Replay / Isolation Forest	27,802–29,325	21,884–22,957	32,462	0
Replay / TFLite-Autoencoder	6,236–6,587	0,099–0,116	6,785	0

Die gesamte Verarbeitungslatenz beginnt beim Host-Leseabschluss des letzten XYZ-Punkts eines Fensters und endet bei der verfügbaren Entscheidung vor dem Schreiben ins Journal. Sie enthält Rohdatenübergabe, Fensteraufbau, Qualitätsprüfung, Mittelwertentfernung, Queue, Standardisierung und Auswertung. Die Sensorwandlungszeit vor der Host-Lesung sowie die Fensterfüllzeit sind nicht enthalten. Der Rechenkern bezeichnet die RMS-Berechnung, IsolationForest.score_samples beziehungsweise nur Interpreter.invoke; Tensorübertragung und Autoencoder-Fehlerberechnung sind gesonderte Anteile.

Das beobachtete Fensterintervall beträgt im Sensorbetrieb 618,050–618,127 ms. Das empirische P99 liegt in allen neun Prozessen darunter. Unter 1.746 gültigen Sensorentscheidungen wurden 0 Fristüberschreitungen gezählt. H2 ist damit im festgelegten Messumfang bestätigt. Ein P99 ist keine Zusage für jede zukünftige Entscheidung und kein Beleg harter Echtzeit.




Abbildung 7-5: Verarbeitungslatenz aus drei eigenen Prozessen je Methode und Betriebsart. Punkte zeigen P99, Linien den Bereich vom Median zum Maximum; die gestrichelte Linie kennzeichnet das kleinste beobachtete Fensterintervall. Quelle: eigene Laufzeitmessungen.

Tabelle 7-8: Prozessressourcen im aktiven Abschnitt [180,300) s; Bereich der drei Prozesse

Betriebsart / Methode	mittlere CPU [% eines Kerns]	maximales RSS [MiB]	gültig / ungültig gesamt	verworfenen Fenster
Sensor / RMS	5,02–5,12	75,47–75,48	582 / 0	0
Sensor / Isolation Forest	8,59–8,62	171,00–171,00	582 / 0	0
Sensor / TFLite-Autoencoder	5,02–5,16	86,30–86,42	582 / 0	0
Replay / RMS	1,65–2,04	142,12–143,61	582 / 0	0
Replay / Isolation Forest	5,06–5,32	238,47–238,48	582 / 0	0
Replay / TFLite-Autoencoder	1,80–1,99	153,38–153,41	582 / 0	0

Die CPU-Auslastung ist aus den ungefähr 100-ms-Prozessmessungen zeitgewichtet; 100 % entsprechen einem logischen Kern. RSS enthält den gesamten jeweiligen Python-Prozess einschließlich Bibliotheken, Vorverarbeitung, Erfassung und Protokollierung. Beim Replay liegt die komplette Quelldatei bereits vor Beginn in einem DataFrame und einer Liste von Datensätzen im Speicher. Dieser zusätzliche Speicher gehört zum Replay-Verfahren und darf

nicht als reiner Modellbedarf oder als identisch zum Sensorbetrieb interpretiert werden. Der kontinuierliche Monitor erfasst die Aufnahme beziehungsweise Wiedergabe; Modellstart und abschließendes erneutes Laden der Sensor-CSV werden außerhalb dieses Ressourcenverlaufs durch Ladezeiten und Umgebungssnapshots dokumentiert. Für CPU und RAM ist der Prozess die Vergleichseinheit. Die erste CPU-Probe besitzt keinen vorherigen Monitorzeitstempel und ist deshalb aus den zeitgewichteten Kennwerten und der CPU-Grafik ausgeschlossen; der ursprüngliche Wert bleibt in der Rohdatei erhalten. Ein sehr kurzer erster Messabstand kann einen überhöhten Quotienten aus CPU-Zeit und Wandzeit erzeugen.




Abbildung 7-6: CPU- und RSS-Verläufe im Sensor-Livebetrieb. Zur Darstellung wurden die CPU-Werte in 1-s-Abschnitten zeitgewichtet und die RSS-Werte gemittelt; die Kennwerte der Tabelle verwenden die ursprünglichen zeitgewichteten Messintervalle. Quelle: eigene Laufzeitmessungen.

Die Rohreihen, maximalen Host-Abstände, Speichertrends, Modellladezeiten, Aufwärmzeiten, Übertragungsanteile und Latenzperzentile je vollständigem Lauf sind im digitalen Laufzeitbericht erhalten. Die Host-Abstände an den Grenzen aufeinanderfolgender

vollständiger Fenster sowie die Intervalle ihrer Ankunft werden ebenfalls separat ausgewiesen; sie sind keine direkte Messung von Sensorwandlungspausen. Die neue Instrumentierung schreibt Entscheidungen und Ressourcen fortlaufend und begrenzt die Queue auf vier Fenster. Rohdaten werden bei einem verworfenen Entscheidungsfenster weiterhin gespeichert.

Die neun Sensoraufnahmen enthalten insgesamt 559.130 XYZ-Punkte bei 207,077267–207,103048 XYZ/s. Der erste Punkt liegt 81,215–97,750 ms nach dem Stellbefehl. Die maximale beobachtete Host-Lesepause über alle Sensorläufe beträgt 30,278 ms. Es wurden 0 Gap-, 0 Overrun- und 0 Sättigungsflags festgestellt. Diese Nullbefunde ersetzen keinen Nachweis unbekannter physischer Verluste.

Über beide Betriebsarten stimmen alle 3.492 ausgegebenen gültigen Scores exakt mit der erneuten eingefrorenen Offline-Auswertung derselben Rohfenster überein. Die maximale absolute Abweichung beträgt 0,0. Auch die Entscheidungen stimmen überein. Die Rückstandsprüfung findet 0 vollständig gebildete, nach Abschluss unverarbeitete Fenster. Die numerische Prüfung beschreibt Konsistenz und ist kein zusätzlicher Erkennungsnachweis.

Zwischen erster und letzter Monitorprobe im aktiven Sensorabschnitt steigt beziehungsweise verändert sich der RSS um 1,219–1,844 MiB. Dieser Verlauf wird nicht als konstanter Speicherbedarf dargestellt. Das Ausbleiben eines Speicherabbruchs und eines wachsenden Fenster-Rückstands in 300 s ist kein unbegrenzter Dauerbetriebsnachweis. Eine Ursache des Speicherverlaufs lässt sich aus RSS allein nicht bestimmen.

Eine getrennte explorative Speicherprobe führte sechsmal dieselbe gespeicherte Aufnahme durch den Fensteraufbau und den RMS-Auswerter. Sie enthielt weder Sensorzugriff noch Queue oder Journale. Nach 1.164 Auswertungen waren rund 443 KiB aktuelle Python-Allokationen registriert; nach einem expliziten GC-Aufruf waren es rund 89 KiB. Der RSS sank dabei nicht entsprechend. Diagnose-Snapshots verursachen selbst Speicherbedarf. Die Probe weist damit keine unbegrenzte Speicherung sämtlicher Fenster nach, erklärt aber auch nicht den gesamten Speicherverlauf des Sensorbetriebs. Sie ist kein weiterer Laufzeitbenchmark. Einzelwerte und Einschränkungen stehen im digitalen Speicherbericht unter B7.

Das TFLite-Modell belegt 14.084 Byte, der gespeicherte Isolation Forest 3.072.589 Byte und der gemeinsame Scaler 639 Byte. Die Dateigrößen sind von den gemessenen Prozessspeichern zu unterscheiden.

Softwareumgebung: Raspberry Pi 5 mit vier logischen Kernen, 64-Bit-Linux, Python 3.13.5, NumPy 2.5.1, pandas 3.0.3, scikit-learn 1.9.0, ai-edge-litert 2.1.6 und psutil 7.2.2. OMP_NUM_THREADS, OPENBLAS_NUM_THREADS und MKL_NUM_THREADS waren auf 1 gesetzt. Die Umgebung und Temperatur-/Drosselungsrücklesungen wurden vor und nach jedem Prozess protokolliert. Es lief keine GUI. Kurze Statusabfragen und leichte Dokumentvorbereitung erfolgten im Hintergrund; absichtliche Trainings-, Test- und Renderinglast war während der Messmatrix ausgesetzt.

Nach jedem Sensorlauf und abschließend wurde 0 % PWM zurückgelesen. Dies dokumentiert den Steuerungszustand, nicht einen neuen mechanischen Sichtnachweis. Die

längeren gesamten Auszeiten ergeben sich aus vorherigem Stopp, Abschluss und Vorbereitung des nächsten Prozesses; identisch sind nur die vorgesehenen zusätzlichen 60 s. Für einen unbegrenzten Dauerbetrieb, GUI-Zusatzlast oder einen Ausfall des Rechners wird kein Nachweis behauptet.

7.8 Erfüllungsgrad der Anforderungen

Die Tabelle ordnet die Ergebnisse den ursprünglichen Anforderungen aus Kapitel 4 zu. „Nachgewiesen“ bezieht sich stets auf den angegebenen Versuchsumfang. Ein dokumentierter Teilnachweis wird nicht mit vollständiger Erfüllung gleichgesetzt. Die MUSS-Prioritäten werden durch schwache Ergebnisse oder ausstehende Messungen nicht nachträglich verändert.

Tabelle 7-9: Nachweisstand der Anforderungen A1–A13

ID	Stand	Beleg und Grenze
A1	Teilweise nachgewiesen	XYZ, Einheit, Zeitstempel, Flags, Host-Abstände und Spektren geprüft; physikalischer Sensortakt, genaue nutzbare Bandbreite und unbekannte physische Verluste nicht abschließend bestimmt.
A2	Nachgewiesen	Ganze Aufnahmen getrennt; Training und Kalibrierung nur normal; Scaler ausschließlich an Trainingspunkten angepasst.
A3	Nachgewiesen	Identische 128er-Testfenster, gemeinsame Quantilregel und eingefrorene Vorverarbeitung für alle drei Methoden.
A4	Im Messumfang nachgewiesen	Automatische lokale Verarbeitung und maschinenlesbare Entscheidungen; ungültige Fenster getrennt behandelt.
A5	Nachgewiesen	Aufnahme-, Protokoll-, Modell- und Codekennungen sowie Hashes und Umgebungsdaten gespeichert.
A6	Nachgewiesen	Ausführung auf dem Raspberry Pi; numerischer Konvertierungsvergleich und identischer Live-/Offline-Datenweg geprüft.
A7	Siehe Abschnitt 7.7	P99 und Fristüberschreitungen gegen das beobachtete Fensterintervall geprüft; keine harte Echtzeitgarantie.
A8	Für endliche Läufe geprüft	CPU, RSS, Modellgrößen, Queue und Verluste gemessen; kein Nachweis unbegrenzten Dauerbetriebs.
A9	Teilweise nachgewiesen	Fehlalarme je Normalaufnahme sowie Verwechslungszahlen und deskriptive Kennzahlen der kontrollierten Änderung; keine belastbare allgemeine Defektleistung.
A10	Nachgewiesen	Drei normale 50%-Tests bei unverändertem Paket; Vergleich zu den vorab bestimmten 75%-Normalreferenzen.
A11	Teilweise nachgewiesen	Aufbauversionen und Schritte dokumentiert; unabhängige Normalstarts vorhanden, aber nur eine abgeschlossene unabhängige Plattenfolge und keine vollständige Rückkehr zum vorigen Mittelwert.

ID	Stand	Beleg und Grenze
A12	Optional, nicht Teil des Nachweises	Frühere Oberfläche vorhanden; Integration und Zusatzlast des eingefrorenen Pakets nicht als geprüft ausgewiesen.
A13	Nachgewiesen	Eindeutige Aufnahmen, erhaltene Rohdaten, geordneter Abschluss und 0%-Fehlerpfad durch Läufe und Softwaretests geprüft.

8 Diskussion

8.1 Aussagekraft des Methodenvergleichs

Die Arbeit trennt drei Ebenen: die korrekte Softwareausführung, die Beschreibung der gemessenen Versuchszustände und die Generalisierung auf bislang ungesehene Fehler. Für die erste Ebene liegen konsistente Offline- und Live-Datenwege sowie numerische Modellprüfungen vor. Für die zweite Ebene stehen unabhängige Normalaufnahmen, eine kontrollierte Luftstromfolge und ein zweiter normaler Betriebspunkt zur Verfügung. Für die dritte Ebene reicht diese Datenbasis nicht aus.

Die höhere Komplexität des Autoencoders führt im vorliegenden Versuch nicht zu einer nachgewiesenen Überlegenheit. Er erzeugt in einer Normalreferenz zahlreiche Fehlalarme und markiert den Plattenzustand gar nicht. Die einfacheren Verfahren unterscheiden den veränderten Zustand ebenfalls nur schwach. Diese Ergebnisse bleiben Bestandteil der Evaluation. Sie werden nicht durch neue Schwellen, ausgesuchte Fenster oder nachträgliches Nachtraining verbessert. Eine methodisch einheitliche Prüfung kann daher zu dem Ergebnis führen, dass das geprüfte Paket für den gewählten Zustand nicht ausreichend empfindlich ist.

H1 setzt einen Vergleich der F1-Werte unter definierten Versuchsanomalien voraus. Die äußere Luftstromveränderung ist zwar absichtlich herbeigeführt, aber kein nachgewiesener Defekt. Zudem liegt nur eine unabhängige veränderte Aufnahme vor. Ein allgemeiner F1-Nachweis für Defekterkennung wird deshalb nicht beansprucht. Der beobachtete Alarmanteil ist für den konkret geänderten Zustand beschreibbar; eine geeignete Fehlerklasse oder deren spätere Häufigkeit wird dadurch nicht festgelegt. Die ergänzend im Anhang berechneten F1-Werte beziehen sich ausschließlich auf das bereits vorab vergebene Zustandslabel der einen Plattenfolge. Sie betragen 6,93 % für RMS, 4,04 % für Isolation Forest und 0 % für den Autoencoder. Für dieses begrenzte Label ist H1 somit nicht bestätigt; eine Überlegenheit des neuronalen Hauptverfahrens oder eine allgemeine Defektleistung ist nicht belegt.

Die Normaltests zeigen, dass die Normalvalidierung die tatsächlich beobachtete Variation zwischen Starts nur begrenzt repräsentiert. Eine auf einem normalen Validierungslauf kalibrierte obere 99%-Schwelle ergibt nicht automatisch 1 % Fehlalarme in späteren normalen Aufnahmen. Die Unterschiede betreffen sowohl das physische Signal als auch die achsenabhängigen Modellfehler. Weitere Normalläufe könnten die Variation genauer beschreiben, würden aber die bereits gemessenen Fehlalarmraten des eingefrorenen Pakets nicht rückwirkend ändern.

8.2 Einlaufzeit, Aufstellung und Vorverarbeitung

Der Abschnitt von 180 bis 300 s wurde vor den unabhängigen Tests festgelegt. Er entfernt die unmittelbare Startphase aus der Modellbewertung, garantiert aber keine stationäre Verteilung. Ein Unterschied zwischen zwei Startmittelwerten und ein zeitlicher Trend

innerhalb eines Starts sind verschiedene Befunde. Nicht überlappende RMS-Bereiche widerlegen für sich genommen keine geeignete Einlaufzeit. Umgekehrt belegen ähnliche Mittelwerte oder eine optisch ruhige Kurve keine allgemeine Reproduzierbarkeit. Die vorliegenden Verläufe werden deshalb ohne nachträgliche Abschnittsanpassung berichtet.

Die Aufbauversion ist Teil der Gültigkeitsgrenze. Änderungen von Sensorbefestigung und Lüfteraufstellung wurden als neue Versionen behandelt. Alte liegende Aufnahmen wurden nicht mit den v4-Daten zu einer gemeinsamen Normalreferenz vermischt. Ein stärkeres Befestigen des heutigen Aufbaus könnte sein dynamisches Verhalten verändern und würde eine neue Datenbasis erfordern. Es ist keine reine Softwarekorrektur. Der eingefrorene Vergleich lässt sich wissenschaftlich abschließen, ohne den Aufbau so lange zu verändern, bis die Kennzahlen günstiger ausfallen.

Die Vorverarbeitung entfernt pro Achse und Fenster den Gleichanteil. Dadurch wird die statische Orientierung nicht direkt als Anomaliesignal verwendet. Die anschließende Skalierung stellt jedoch nicht automatisch alle physikalischen Richtungen gleich. Sie teilt durch die im Training geschätzte jeweilige Achsenstreuung. Der Zuwachs einer bereits stark streuenden Achse kann daher im standardisierten Score weniger ins Gewicht fallen als kleinere Veränderungen einer zuvor ruhigen Achse. Dies ist eine dokumentierte Eigenschaft des gewählten Verfahrens. Eine andere Gewichtung wäre eine neue Modell- und Vorverarbeitungsversion, deren Nutzen unabhängig geprüft werden müsste.

8.3 Technische Grenzen und Übertragbarkeit

Die lokale Laufzeitprüfung beantwortet eine andere Frage als die Erkennungstests: ob die gespeicherte Verarbeitung auf der Zielhardware im festgelegten Messumfang Schritt halten kann. Numerische Konsistenz und kurze Latenz machen eine fachlich ungeeignete Entscheidung nicht richtig. Ebenso bedeutet eine schwache Zustandstrennung nicht, dass der Erfassungs- oder Ausführungsweg falsch implementiert ist. Die getrennten Nachweise verhindern diese Vermischung.

Die Zeitbewertung beginnt mit dem hostseitig vollständigen Fenster. Sie enthält weder die physikalische Fensterfüllzeit noch eine unbekannte Verzögerung zwischen Sensorwandlung und Host-Leseabschluss. Ein endlicher Test unter gewöhnlichem Linux ist keine harte Echtzeitusage. Die optionale GUI wurde aus dem abschließenden Messweg ausgeschlossen; ihre frühere Existenz ersetzt keinen Nachweis ihrer Zusatzlast mit dem neuen Paket.

Die unbekannte tatsächliche Drehzahl begrenzt die physikalische Interpretation. Ein vorhandener PWM-Registerwert belegt eine Stellvorgabe, aber keine gemessene Signalfrequenz oder Rotationsgeschwindigkeit. Die um rund 3,5 % höhere beobachtete Punktzahl gegenüber der nominalen ODR ist konsistent dokumentiert. Sie bleibt als offene Ursache bestehen. Eine nachträgliche Umbenennung in einen 207-Hz-Sensorbetrieb wäre ohne Referenzmessung nicht gerechtfertigt.

Die Generalisierung bleibt auf diesen Lüfter, die dokumentierte Montage, die verwendete Sensorik und kurze Messserien beschränkt. Weder wechselnde Geräte noch langfristige

Alterung, Temperaturbereiche oder verschiedene tatsächliche Defekte wurden systematisch untersucht. Die Arbeit liefert damit einen nachvollziehbaren Pilotvergleich mit klaren Grenzen und keine betriebsfertig validierte industrielle Fehlerdiagnose.

9 Ausblick und verbleibende Nachweise

Der vorhandene Modellstand sollte als abgeschlossener Pilotstand erhalten bleiben. Für die Dokumentation ist keine weitere Wiederholung gleicher Normalstarts erforderlich, nur um eine günstigere durchschnittliche Kennzahl zu erreichen. Künftige Messungen sollten jeweils eine benannte offene Frage beantworten und vorab einen eigenen Auswertungsplan erhalten.

Die erste offene physikalische Frage betrifft die Zeitbasis. Ein kleinster gezielter Versuch wäre eine unabhängig referenzierte Messung des Data-Ready-Takts beziehungsweise eines bekannten Anregungssignals zusammen mit dem unveränderten FIFO-Datenweg. Dafür müssen geeignete Messmittel, Signalanbindung und zulässige elektrische Pegel vorab geklärt werden. Das Ergebnis könnte die Abweichung zwischen nominaler ODR und Host-Durchsatz einordnen; aus den vorhandenen Dateien allein ist diese Ursache nicht sicher auflösbar.

Eine zweite Frage betrifft die tatsächliche Drehzahl. Dafür wäre ein bestätigter separater Tachoanschluss oder ein berührungsloses Referenzmessgerät erforderlich. GPIO18 bleibt der PWM-Ausgang und wird nicht gleichzeitig als bestätigter Tachoeingang behandelt. Beschaltung, Pegel und Impulse pro Umdrehung müssten dokumentiert werden. Erst danach ließen sich Stellvorgabe, Drehzahl und Frequenzmerkmale nachvollziehbar miteinander vergleichen.

Für einen erweiterten Erkennungsnachweis muss zunächst festgelegt werden, welcher kontrolliert veränderte Zustand die Zielklasse bilden soll. Eine weitere äußere Luftstromänderung könnte die Empfindlichkeit gegenüber diesem Betriebszustand untersuchen, wäre aber weiterhin kein automatischer Defektnachweis. Manipulationen an einem laufenden Rotor sind ausgeschlossen. Änderungen erfolgen ausschließlich nach Trennen der externen Versorgung und bestätigtem Stillstand; Sensor und Aufstellung bleiben für einen Modellvergleich unverändert. Die konkreten sicheren Grenzen einer neuen Änderung sind vor ihrer Umsetzung zu prüfen.

Ein geeigneter Folgeplan würde mehrere vollständige unabhängige Normal-Änderung-Normal-Folgen vorsehen. Geometrie, Stellvorgabe, Auszeiten, Messdauer, Bewertungsabschnitt und Labels werden vorher fixiert. Die Rückkehrreferenzen prüfen, ob das Entfernen der Änderung das zuvor beobachtete Signal wiederherstellt. Die Reihenfolge und weitere Störeinflüsse sind so zu planen, dass Zustands- und Zeitunterschiede besser unterscheidbar werden. Die Anzahl der Wiederholungen folgt der gewünschten Genauigkeit auf Aufnahmeebene und nicht der bloßen Zahl verfügbarer Fenster.

Eine neue Modellversion wäre erst begründet, wenn ein vorher festgelegtes Ziel besteht, beispielsweise robustere Normalabdeckung oder höhere Empfindlichkeit für eine klar definierte Änderung. Denkbar sind zusätzliche unabhängige Entwicklungsaufnahmen, andere Achsengewichtungen oder spektrale Merkmale. Sie dürfen nicht durch Optimieren auf die hier bereits ausgewerteten Testfenster als unabhängig bestätigt gelten. Nach Änderungen sind neue, vollständig unbenutzte Testaufnahmen nötig. Training, Skalierung, Validierung und Test bleiben nach vollständigen Aufnahmen getrennt.

Die GUI bleibt eine optionale Erweiterung. Für ihre Einbindung müssten die gespeicherten Entscheidungen des validierten Datenwegs angezeigt, ungültige oder veraltete Ausgaben erkennbar gemacht und zusätzliche CPU-, RAM- und Latenzkosten unter ansonsten gleichen Bedingungen gemessen werden. Dies ist eine getrennte Software- und Messaufgabe; es ist keine Voraussetzung dafür, den bereits geprüften Betrieb ohne Oberfläche nachvollziehbar zu berichten.

10 Fazit

Die Arbeit zeigt, wie ein lokaler Vergleich von RMS-Schwelle, Isolation Forest und TFLite-Autoencoder auf einem Raspberry Pi 5 nachvollziehbar umgesetzt werden kann. Die Datenkette verbindet dreiachsige Beschleunigungserfassung, Qualitätsprüfung, Fensterbildung, gespeicherte Vorverarbeitung, Entscheidung und Protokollierung. Ganze Aufnahmen wurden vor der Fensterbildung Training, Validierung oder Test zugeordnet. Das anschließend eingefrorene Paket blieb während der unabhängigen Prüfungen unverändert.

FF1 wird durch die Anforderungsanalyse, den Variantenvergleich und die dokumentierte Realisierung beantwortet. Der kleine Lüfterprüfstand ermöglicht wiederholte lokale Messungen und eine äußere Luftstromänderung. Die Auswahl des kostengünstigen ADXL345 bringt jedoch Grenzen bei Zeitbasis, Bandbreitennachweis und physikalischer Interpretation mit sich. Eine unbekannte Drehzahl oder Sensortaktabweichung wird nicht als erfüllter Nachweis behandelt.

Zu FF2 liegen vergleichbare Entscheidungen auf identischen unabhängigen Testfenstern vor. Die Methoden zeigen unterschiedliche Fehlalarme zwischen normalen Starts. Der Autoencoder erkennt die untersuchte Plattenänderung in keinem der 194 gültigen Fenster, während RMS sieben und Isolation Forest vier Fenster markieren. Die explorative Fehleranalyse erklärt diesen Befund durch die gespeicherte Achsenskalierung, geringere X- und Y-Rekonstruktionsfehler und Überschneidungen mit bekannter normaler Variation. Eine allgemein erfolgreiche Anomalieerkennung oder eine Überlegenheit des Autoencoders ist daraus nicht ableitbar. Der ursprünglich angestrebte umfassende Defektvergleich bleibt ein Teilnachweis.

FF3 wird durch getrennte Ressourcen- und Latenzmessungen im Sensorbetrieb und im zeitgetreuen Replay konkretisiert. Die Angaben in Abschnitt 7.7 beziehen sich auf definierte Prozessgrenzen, eine endliche Messdauer und das beobachtete Fensterintervall. Sie beschreiben die technische Ausführbarkeit des Datenwegs und ersetzen keine Beurteilung der fachlichen Richtigkeit seiner Entscheidungen.

FF4 ist durch einen zweiten normalen Betriebspunkt bei 50 % PWM untersucht. Das Paket wurde dafür nicht angepasst. RMS und Isolation Forest zeigen in diesen Aufnahmen geringere zusammengefasste Fehlalarmraten als in den festgelegten 75%-Normalreferenzen; beim Autoencoder ist der Anteil geringfügig höher. Die zeitlich getrennten Reihen begründen keine allgemeine kausale Wirkung des Tastgrads. H3 wird daher nur methodenspezifisch beschrieben und nicht pauschal bestätigt.

Der wissenschaftliche Beitrag liegt in der konsistenten und überprüfbaren Umsetzung sowie in der offenen Bewertung ihrer Grenzen. Die Messungen zeigen, dass stärkere physische Vibration, ein größerer Modellscore und eine richtige Anomalieentscheidung verschiedene Sachverhalte sind. Das dokumentierte Pilotpaket bildet eine Grundlage für gezielt geplante weitere Untersuchungen. Es ist kein vollständig validiertes Defekterkennungssystem, und die nicht bestätigten Erwartungen bleiben als Ergebnisse der Arbeit erhalten.

Anhang

Digitale Belege und Zuordnung

Die folgenden Pfade sind relativ zur Projektwurzel `masterarbeit-edge-ai` angegeben. Rohdaten werden nicht in die Worddatei kopiert. Die jeweiligen maschinenlesbaren Berichte enthalten Aufnahme-IDs, Zeitstempel, Protokolle und vollständige Artefakthashes. Historische Ergebnisse wurden für diesen Abschluss nicht überschrieben.

Tabelle A-1: Verzeichnis der maßgeblichen digitalen Belege

Kennu ng	Inhalt	Projektpfad
B1	Eingefrorenes Modellpaket und Trainingsnachweis	results/upright_v4_training_pilot_20260911_130614/run_001/
B2	Drei unabhängige normale 75-%-Tests	results/upright_v4_independent_normal_20260911_133047/
B3	Zusätzlicher Normaltest und dokumentierter abgebrochener Plattenstart	results/upright_v4_frozen_airflow_test_20260911_164040/
B4	Vollständiger unabhängiger Test Normal → Platte → Normal	results/upright_v4_frozen_airflow_test_20260912_073015/
B5	Explorative Fehleranalyse auf identischen Modellfenstern	results/upright_v4_exploratory_diagnosis_20260912_081728/
B6	Drei unabhängige normale 50-%-Tests	results/upright_v4_second_pwm50_20260912_091000/
B7	Abschließende Sensor-/Replay-Laufzeitprüfung und Erhaltungsnachweis	results/upright_v4_finalization_20260912_103145/
B8	Vor dem Training erstellte Spektralprüfung der Entwicklungsaufnahmen	results/upright_v4_spectral_review_20260911_114502/

Die eindeutige Kurzbezeichnung des eingefrorenen Pakets lautet `pilot_bundle.json` im Unterverzeichnis `frozen` von B1. Sein SHA-256-Wert ist `cec1859bfb354bafef77a619e6d2c1ffd85b50787c87595aba9a1e20a80cdae5`. Der vollständige Manifest- und Artefaktabgleich ist in den digitalen Belegen enthalten; die Kurzpfade der Tabelle ersetzen diese Prüfsummen nicht.

Die letzte Softwareergänzung ist versioniert in `pilot_runtime_final.py`, `pilot_stream_final.py`, `pilot_recorder_final.py` und `run_final_runtime_evidence.py`. Sie verändert weder das eingefrorene Paket noch seine vier überprüften ursprünglichen Vorverarbeitungs- und Auswertungsmodule. Die Tests und das vor dem Lauf fixierte Protokoll sind B7 zugeordnet. Die 300-s-Rohdaten des Sensorbetriebs liegen separat unter `data/upright_v4_finalization_20260912_103145/runtime_evidence/`.

Ergänzende Kennzahlen des kontrollierten Zustandslabels

Diese nachträgliche, deskriptive Zählung verwendet ausschließlich die bereits gespeicherten Labels und Entscheidungen der vollständigen unabhängigen Folge vom 12. September. Sie wurde für den Berichtsabschluss ergänzt und war kein neuer Mess- oder Abstimmungsversuch. Positiv bezeichnet `airflow_modified`, negativ die beiden normalen Referenzen derselben Folge. Das positive Label war bereits vor der Auswertung festgelegt; es wird nicht nachträglich in einen Defekt umbenannt. Modelle, Schwellen, Eingaben und der Abschnitt [180,300] bleiben unverändert.

Tabelle A-2: Verwechslungszahlen der einen Plattenfolge auf identischen Fenstern

Methode	TP: Änderung erkannt	FN: Änderung übersehen	FP: normal auffällig	TN: normal unauffällig
RMS	7	187	1	387
Isolation Forest	4	190	0	388
Autoencoder	0	194	55	333

Tabelle A-3: Deskriptive Kennzahlen für das Zustandslabel; alle Angaben in Prozent

Methode	Precision	Recall	F1	Fehlalarmrate	Accuracy
RMS	87,50	3,61	6,93	0,26	67,70
Isolation Forest	100,00	2,06	4,04	0,00	67,35
Autoencoder	0,00	0,00	0,00	14,18	57,22

Je Methode liegen 582 gültige und keine ungültigen Fenster vor: 388 aus zwei Normalaufnahmen und 194 aus einer veränderten Aufnahme. Die Berechnungen folgen den Definitionen in Kapitel 2. Eine Precision von 100 % beim Isolation Forest betrifft lediglich vier Alarmer; zugleich bleiben 190 der 194 veränderten Fenster unmarkiert. Der größte Teil der scheinbar hohen Accuracy entsteht durch die zwei normalen Referenzen. Ein Verfahren, das immer normal ausgäbe, erreichte auf dieser Klassenverteilung bereits 66,67 % Accuracy. Diese Kennzahl ist hier deshalb kein Beleg für brauchbare Änderungserkennung.

Die Fenster sind zeitlich abhängig, und der positive Zustand besitzt nur eine vollständige Aufnahme. Die Kennzahlen werden weder als allgemeiner Defekt-Recall noch als unabhängiger Reproduzierbarkeitsnachweis verwendet. Insbesondere werden die reinen Normaltests nicht um erfundene positive Fälle ergänzt. Die Zählung und die Hashes ihrer Quellen liegen separat in `controlled_state_descriptive_metrics.json` unter B7; historische Berichte bleiben unverändert.

Lesen der Messdateien

Eine CSV-Zeile entspricht einem vollständigen XYZ-Messpunkt. Neben Beschleunigung und Label enthalten die Dateien Softwareindex, Host-Zeitstempel und Qualitätsmerkmale. Die relative Erfassungszeit ist aus der monotonen Host-Uhr abgeleitet; `sample_index/200` ist lediglich eine nominelle Sensorzeit. Pro Zustand werden eigene Dateien verwendet. Der

erste Messpunkt und der Stellbefehl besitzen getrennte Zeitstempel. Eine aus dem Dateinamen abgeleitete Uhrzeit ersetzt diese Angaben nicht.

Ein gültiges Modellfenster besteht aus 128 aufeinanderfolgenden XYZ-Punkten desselben Aufnahmelaufs im Abschnitt [180,300) s. Ein Rest von weniger als 128 Punkten wird als unvollständiger Rest dokumentiert. Er wird nicht zu einem normalen Fenster ergänzt. Bei erkannten Qualitätsfehlern wird keine normale Entscheidung erzeugt. Die 5-s-Diagnostik nutzt dagegen Zeitabschnitte mit einer eigenen Mittelwertentfernung je Achse und besitzt eine andere Punktzahl und Aufgabenstellung.

Das Kontrolljournal beschreibt Stellbefehle und zurückgelesene Einstellungen. Sichtbestätigungen sind Nutzerbeobachtungen und werden nicht durch Softwarewerte ersetzt. Für unbeaufsichtigt freigegebene spätere Serien werden nicht vorhandene neue mechanische Beobachtungen nicht erfunden. Insbesondere bedeutet die zuletzt zurückgelesene Vorgabe 0 % nicht automatisch einen dokumentierten vollständigen mechanischen Stillstand.

Literaturverzeichnis

- Analog Devices (2022). ADXL345: 3-Axis, ± 2 g/ ± 4 g/ ± 8 g/ ± 16 g Digital Accelerometer. Datenblatt, Revision G, Mai 2022. <https://www.analog.com/media/en/technical-documentation/data-sheets/adxl345.pdf> (Abruf: 12.09.2026.)
- Analog Devices (2025). ADXL354/ADXL355: Low Noise, Low Drift, Low Power, 3-Axis MEMS Accelerometers. Datenblatt, Revision D, Juni 2025. https://www.analog.com/media/en/technical-documentation/data-sheets/adxl354_adxl355.pdf (Abruf: 12.09.2026.)
- Antonini, M., Pincheira, M., Vecchio, M., & Antonelli, F. (2023). An Adaptable and Unsupervised TinyML Anomaly Detection System for Extreme Industrial Environments. *Sensors*, 23(4), 2344. <https://doi.org/10.3390/s23042344> (Abruf: 12.09.2026.)
- ARCTIC (o. J.). Specifications: P12 Pro PST. Technisches Datenblatt. https://www.arctic.de/media/2c/de/c6/1750758983/Spec_Sheet_P12_Pro_PST_EN.pdf (Abruf: 12.09.2026.)
- Buttazzo, G. C. (2011). *Hard Real-Time Computing Systems: Predictable Scheduling Algorithms and Applications* (3. Aufl.). Springer. <https://doi.org/10.1007/978-1-4614-0676-1> (Abruf: 12.09.2026.)
- Chandola, V., Banerjee, A., & Kumar, V. (2009). Anomaly Detection: A Survey. *ACM Computing Surveys*, 41(3), Artikel 15, 1–58. <https://doi.org/10.1145/1541880.1541882> (Abruf: 12.09.2026.)
- Department for Communities and Local Government (2009). *Multi-criteria analysis: a manual*. London. ISBN 978-1-4098-1023-0. <https://www.gov.uk/government/publications/multi-criteria-analysis-manual-for-making-government-policy> (Abruf: 12.09.2026.)
- Garay, C. E., Miranda Bonomi, F. A., Mansilla, G. N., Fagre, M., Guzmán, S. G., Ritorto, P. A., Perez, F. I., & Katz, M. (2026). A Multimodal TinyML-Based Predictive Maintenance Architecture for Industrial IoT in the 6G Era. *Sensors*, 26(14), 4536. <https://doi.org/10.3390/s26144536> (Abruf: 12.09.2026.)
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Insbesondere Kapitel 14: Autoencoders. <https://www.deeplearningbook.org/> (Abruf: 12.09.2026.)
- Google (2026a). Convert TensorFlow models. LiteRT-Dokumentation, Stand 28.05.2026. https://developers.google.com/edge/litert/conversion/tensorflow/convert_tf (Abruf: 12.09.2026.)
- Google (2026b). Post-training quantization. LiteRT-Dokumentation, konsultierte Fassung 2026. https://developers.google.com/edge/litert/conversion/tensorflow/quantization/post_training_quantization (Abruf: 12.09.2026.)
- Google (2026c). Quickstart for Linux-based devices with Python. LiteRT-Dokumentation, konsultierte Fassung 2026. <https://developers.google.com/edge/litert/microcontrollers/python>
<https://developers.google.com/edge/api/tflite/python/tf/lite/Interpreter> (Abruf: 12.09.2026.)
- Google (2026d). Install TensorFlow with pip. TensorFlow-Dokumentation, konsultierte Fassung 2026. <https://www.tensorflow.org/install/pip> (Abruf: 12.09.2026.)
- Jardine, A. K. S., Lin, D., & Banjevic, D. (2006). A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mechanical Systems and Signal Processing*, 20(7), 1483–1510. <https://doi.org/10.1016/j.ymssp.2005.09.012> (Abruf: 12.09.2026.)
- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), Artikel 15. <https://doi.org/10.1145/2382577.2382579> (Abruf: 12.09.2026.)
- Knap, P., Jachymczyk, U., & Lalik, K. (2026). Leakage-Safe, Reproducible Benchmarking for Vibration-Based Fault Diagnosis. *PHM Society European Conference*, 9(1), 1–8. <https://doi.org/10.36001/phme.2026.v9i1.4924> (Abruf: 12.09.2026.)

- Lessmeier, C., Kimotho, J. K., Zimmer, D., & Sextro, W. (2016). Condition Monitoring of Bearing Damage in Electromechanical Drive Systems by Using Motor Current Signals of Electric Motors: A Benchmark Data Set for Data-Driven Classification. European Conference of the Prognostics and Health Management Society. https://mb.uni-paderborn.de/fileadmin-mb/kat/PDF/Veroeffentlichungen/20160703_PHME16_CM_bearing.pdf (Abruf: 12.09.2026.)
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. Proceedings of the Eighth IEEE International Conference on Data Mining, 413–422. <https://doi.org/10.1109/ICDM.2008.17> (Abruf: 12.09.2026.)
- NASA (2023). 6.8 Decision Analysis. Webfassung des NASA Systems Engineering Handbook. <https://www.nasa.gov/reference/6-8-decision-analysis/> (Abruf: 12.09.2026.)
- NVIDIA (o. J.). Jetson Orin Nano Super Developer Kit. Technische Spezifikationen. <https://www.nvidia.com/de-de/autonomous-machines/embedded-systems/jetson-orin/nano-super-developer-kit/> (Abruf: 12.09.2026.)
- ONNX Runtime developers (o. J.). Python. ONNX Runtime-Dokumentation zur Installation und Ausführung. <https://onnxruntime.ai/docs/get-started/with-python.html> (Abruf: 12.09.2026.)
- Oriental Motor (o. J.). Servo Motor Features Overview. <https://www.orientalmotor.com/servo-motors/technology/servo-motor-features.html> (Abruf: 12.09.2026.)
- PCB Piezotronics (o. J.). Model 356A32: Triaxial Accelerometer. Technische Spezifikationen. <https://www.pcb.com/products?m=356a32> (Abruf: 12.09.2026.)
- Pittino, F., Puggl, M., Moldaschl, T., & Hirschl, C. (2020). Automatic Anomaly Detection on In-Production Manufacturing Machines Using Statistical Learning Methods. *Sensors*, 20(8), 2344. <https://doi.org/10.3390/s20082344> (Abruf: 12.09.2026.)
- PyTorch (o. J.). ExecuTorch Documentation. Dokumentation zum Modellexport und zur lokalen Ausführung. <https://docs.pytorch.org/executorch/stable/index.html> (Abruf: 12.09.2026.)
- Randall, R. B., & Antoni, J. (2011). Rolling element bearing diagnostics—A tutorial. *Mechanical Systems and Signal Processing*, 25(2), 485–520. <https://doi.org/10.1016/j.ymssp.2010.07.017> (Abruf: 12.09.2026.)
- Raspberry Pi Ltd. (o. J.). Raspberry Pi 5. Produktbeschreibung und technische Spezifikationen. <https://www.raspberrypi.com/products/raspberry-pi-5/>
<https://datasheets.raspberrypi.com/rpi5/raspberry-pi-5-product-brief.pdf> (Abruf: 12.09.2026.)
- Raspberry Pi Ltd. (2026). Raspberry Pi 4 Model B. Product Brief, April 2026. <https://pip-assets.raspberrypi.com/categories/545-raspberry-pi-4-model-b/documents/RP-008344-DS-1-raspberry-pi-4-product-brief> (Abruf: 12.09.2026.)
- Ren, H., Anicic, D., & Runkler, T. A. (2021). TinyOL: TinyML with Online-Learning on Microcontrollers. *International Joint Conference on Neural Networks*, 1–8. <https://doi.org/10.1109/IJCNN52387.2021.9533927> (Abruf: 12.09.2026.)
- Ruff, L., Kauffmann, J. R., Vandermeulen, R. A., Montavon, G., Samek, W., Kloft, M., Dietterich, T. G., & Müller, K.-R. (2021). A Unifying Review of Deep and Shallow Anomaly Detection. *Proceedings of the IEEE*, 109(5), 756–795. <https://doi.org/10.1109/JPROC.2021.3052449> (Abruf: 12.09.2026.)
- scikit-learn developers (o. J. a). Common pitfalls and recommended practices. Benutzerhandbuch. https://scikit-learn.org/stable/common_pitfalls.html (Abruf: 12.09.2026.)
- scikit-learn developers (o. J. b). Cross-validation: evaluating estimator performance. Insbesondere Aufteilung gruppierter Daten. https://scikit-learn.org/stable/modules/cross_validation.html (Abruf: 12.09.2026.)

- scikit-learn developers (o. J. c). Metrics and scoring: quantifying the quality of predictions. https://scikit-learn.org/stable/modules/model_evaluation.html (Abruf: 12.09.2026.)
- scikit-learn developers (o. J. d). IsolationForest. API-Dokumentation. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html> (Abruf: 12.09.2026.)
- SciPy developers (o. J. a). Discrete Fourier Transforms (scipy.fft). SciPy-Benutzerhandbuch. <https://docs.scipy.org/doc/scipy/tutorial/fft.html> (Abruf: 12.09.2026.)
- SciPy developers (o. J. b). Signal Processing (scipy.signal), Abschnitt Spectral Analysis. SciPy-Benutzerhandbuch. <https://docs.scipy.org/doc/scipy/tutorial/signal.html#spectral-analysis> (Abruf: 12.09.2026.)
- Shi, W., Cao, J., Zhang, Q., Li, Y., & Xu, L. (2016). Edge Computing: Vision and Challenges. IEEE Internet of Things Journal, 3(5), 637–646. <https://doi.org/10.1109/JIOT.2016.2579198> (Abruf: 12.09.2026.)
- STMicroelectronics (2026). Migrating applications from STM32F7 to STM32H743/H753 MCUs. Application Note AN4936, Fassung vom 09.01.2026. https://www.st.com/resource/en/application_note/an4936-migrating-applications-from-stm32f7-to-stm32h743h753-mcus-stmicroelectronics.pdf
<https://www.st.com/en/microcontrollers-microprocessors/stm32h743-753.html> (Abruf: 12.09.2026.)
- Universität Paderborn, Lehrstuhl Konstruktions- und Antriebstechnik (o. J.). Bearing Data Center. Beschreibung des Lagerprüfstands und des Datensatzes. <https://mb.uni-paderborn.de/en/kat/research/bearing-datacenter> (Abruf: 12.09.2026.)